집수리 AI 견적 및 매칭 플렛폼

TUKTAK

IBM × Red Hat

TEAM 허공답보

백승우 반고호 김지민 전지원 노승태

Contents

01
기획 개요
배경 · 차별점

02
서비스 개요
주요 기능 · 시연영상

03
기술 구조
아키텍처 · CI/CD · 핵심 기능 구현

04
비즈니스 모델
수익 구조 · 확장성

05
트러블 슈팅
문제 상황 · 해결 과정

06
향후 계획
전망 · 확장 계획

Appendix

01 기획 · 개요

배경 · 차별점

TUKTAK

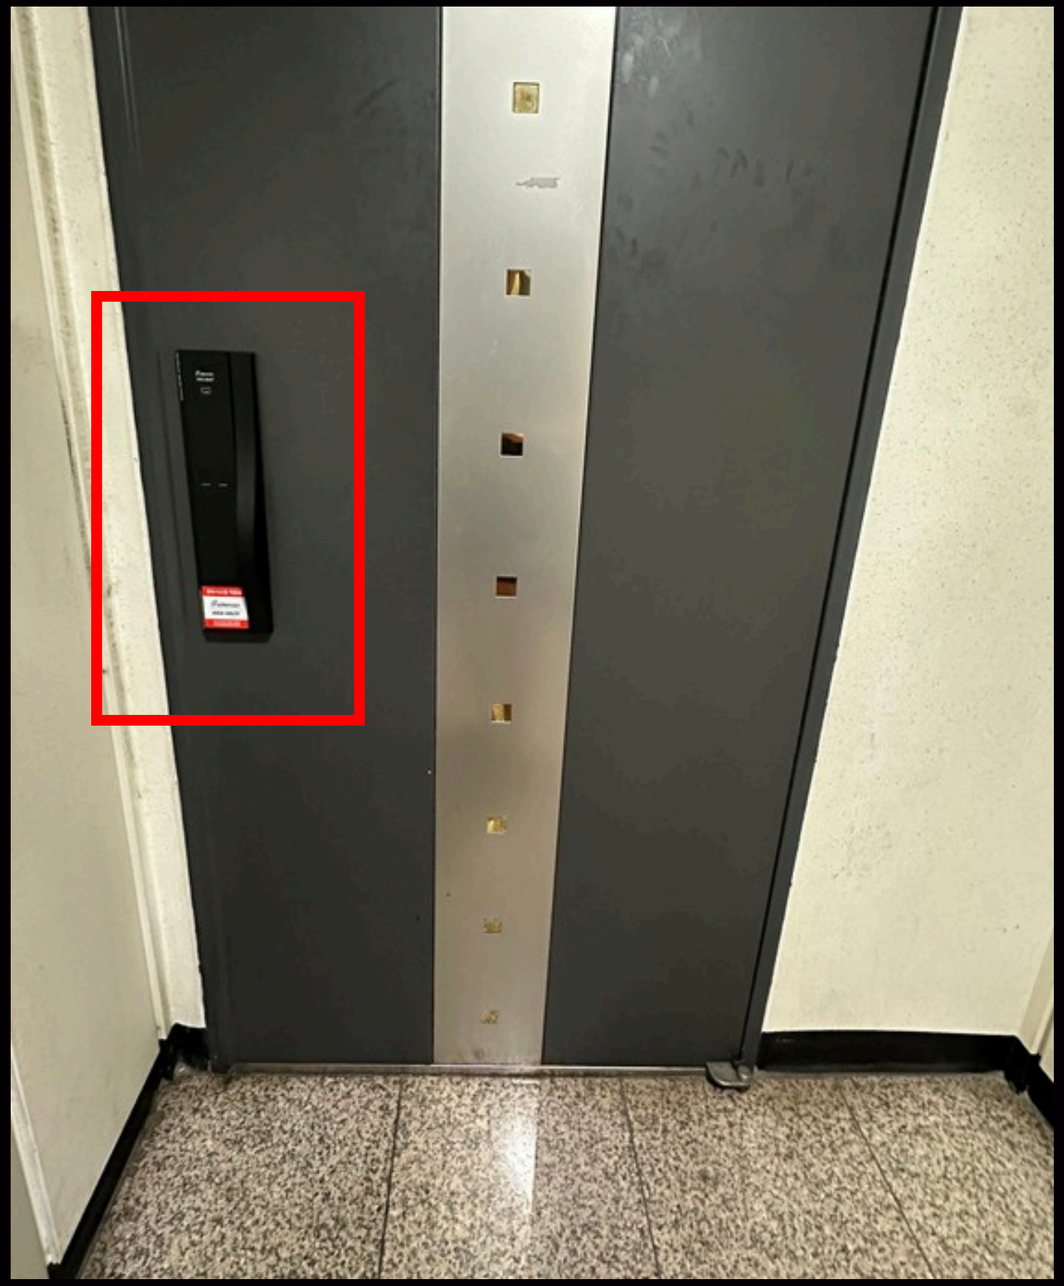

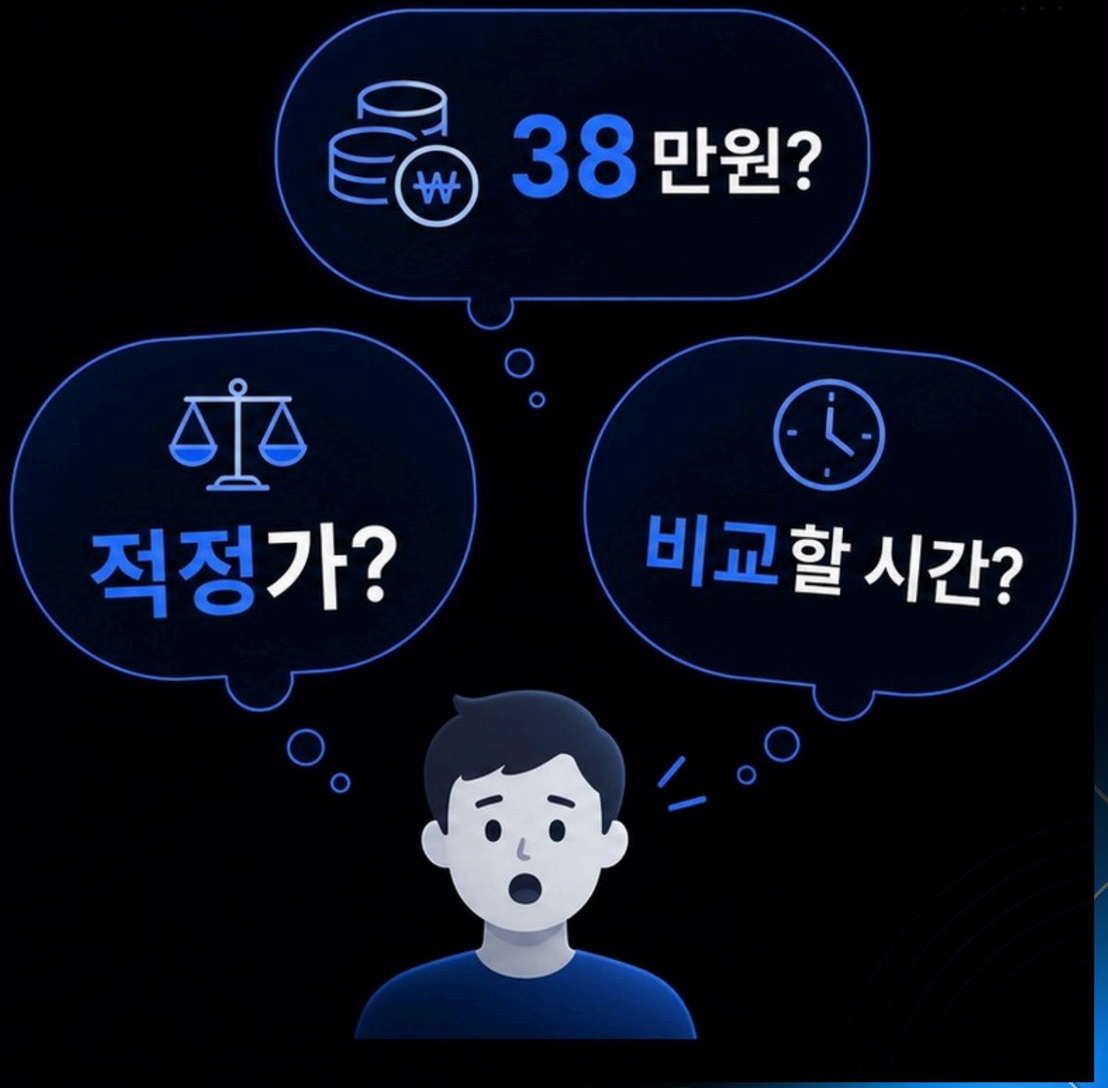

Canva

Problem

실제로 벌어지고 있는 소비자 피해

커뮤니티 후기부터 언론 보도까지, 반복되는 피해 유형

클리앙

"도어락 설치 요금 심하네요"

8만원짜리를 38만원에,
영수증엔 항목도 없었다

클리앙

"화장실 하수구 막혔을 때 참고하세요~"

세 곳에 전화했지만,
다 와봐야 안다고 했다

머니투데이, 2026.07.20

은마아파트 화재 보도

누가, 어떤 자격으로 고치는지
확인할 방법이 없었다

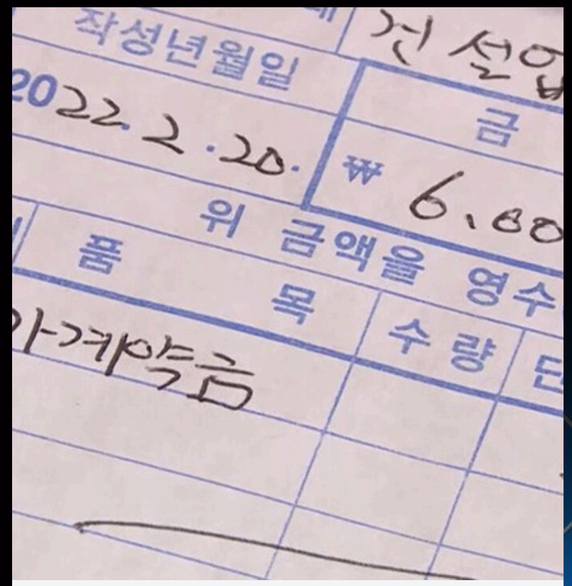

SBS 취재파일

"잔금 안 준다고 현관문까지 떼어가"

업체 상당수가 무면허로 추정되고,
후기·별점도 그대로 믿기 어렵다는 지적

Problem

숫자로 보는 집수리 피해

소비자 10명 중 6명은, 만족스러운 해결을 받지 못합니다

2,556건

2020년~2025년 8월 한국소비자원 접수
인테리어·집수리 피해구제 신청 누적

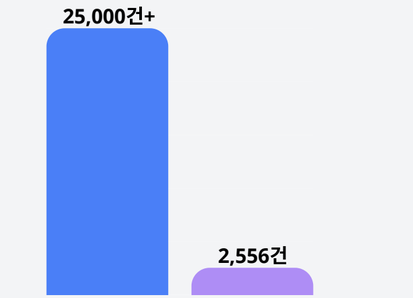

34.0%

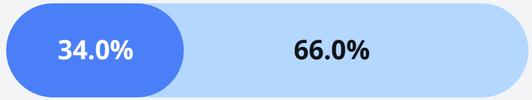

피해구제 단계 평균 합의율
— 나머지 66%는 원만히 해결되지 못하는 구조

피해 신청 사유별 비중

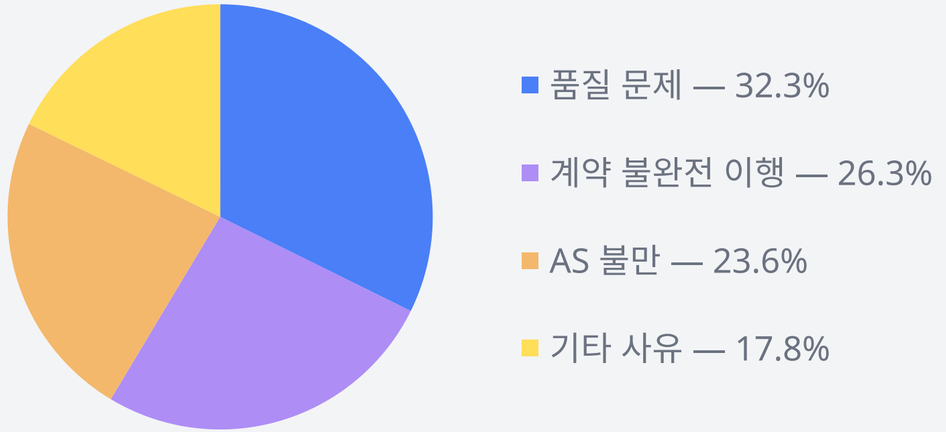

한국소비자원 피해구제 신청 현황(2020~2025.8), 시사저널(2025.10.27) / 한국소비자원 용역중개 플랫폼 실태조사, 경향신문·이데일리(2025.07)

추가비용?

적정가격?

견적비교?

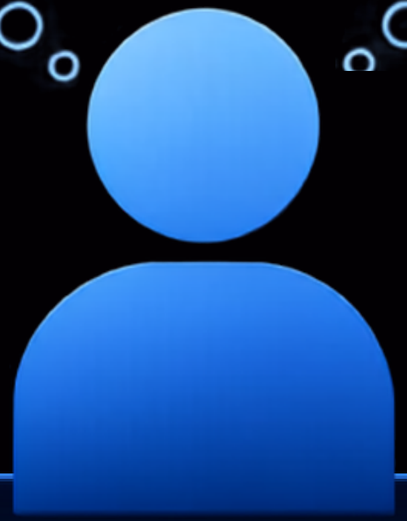

정보 비대칭

리스크 불투명

비교 어려움

신규고객?

제한적인 활동범위

신규 고객 유치 어려움

가격 정보 비공개 관행

제한적인 활동범위

TukTak의 핵심 기능

사용자는 기준을 얻고, 시공자는 새로운 고객과 연결됩니다

AI 견적 서비스

사진+설명으로 예상 비용·시간 확인

AI 리스크 리포트

추가비용·주의사항·체크리스트 사전 안내

역경매 매칭

여러 시공자 제안 비교

고객 : 원하는 **시공의 견적, 발생가능한 위험 인지** 그리고 **합리적인 매칭**
시공자 : 고객의 **개별 지정 X,** 조건에 부합하는 **모든 신규 시공 요청을 수신**

숨고·미소와 무엇이 다른가?

TUKTAK은 시공자 연결 전에, 판단 기준을 먼저 제공합니다

TUKTAK		기존 매칭 서비스
사진+텍스트 기반 AI 견적	VS	텍스트 기반 단순계산 AI 견적
AI 리스크 리포트		사전 리스크 안내 서비스 없음
AI 견적서 기준 제안 역경매		시공자 임의 역경매

사진과 설명 → AI 견적 → 리스크 확인 → 시공자 비교

02 서비스 흐름

주요기능 · 시연영상

TUKTAK

Service

TukTak이 제공하는 기능 List

견적부터 시공 완료까지, TukTak 안에서 모두 해결합니다

STEP 1 - AI 견적 받기

AI 견적
사진 + 설명만으로 예상 가격과 시간 제공

리스크 리포트
공신력 있는 근거 기반 위험 안내

STEP 2 - 매칭 & 소통

역경매 매칭
여러 시공자 경쟁으로 합리적 견적

1:1 채팅
시공자 고객 간 실시간 소통

진행 알림
매칭·시공 진행 상황 알림

매칭·계약 관리
진행 중인 매칭·계약 상태 확인

STEP 3 - 완료 후 관리

시공 이력 확인
완료된 시공 내역 한눈에 조회

리뷰
시공 후 리뷰와 평점으로 신뢰도 확보

견적 이력 관리
내가 받은 AI 견적서 목록 관리

Canva

03 기술 구조

아키텍처 · CI/CD · AI 기술

TUKTAK

Architecture

배포 시스템 아키텍쳐

CI/CD 파이프라인 기반의 자동화된 배포 및 운영 아키텍처

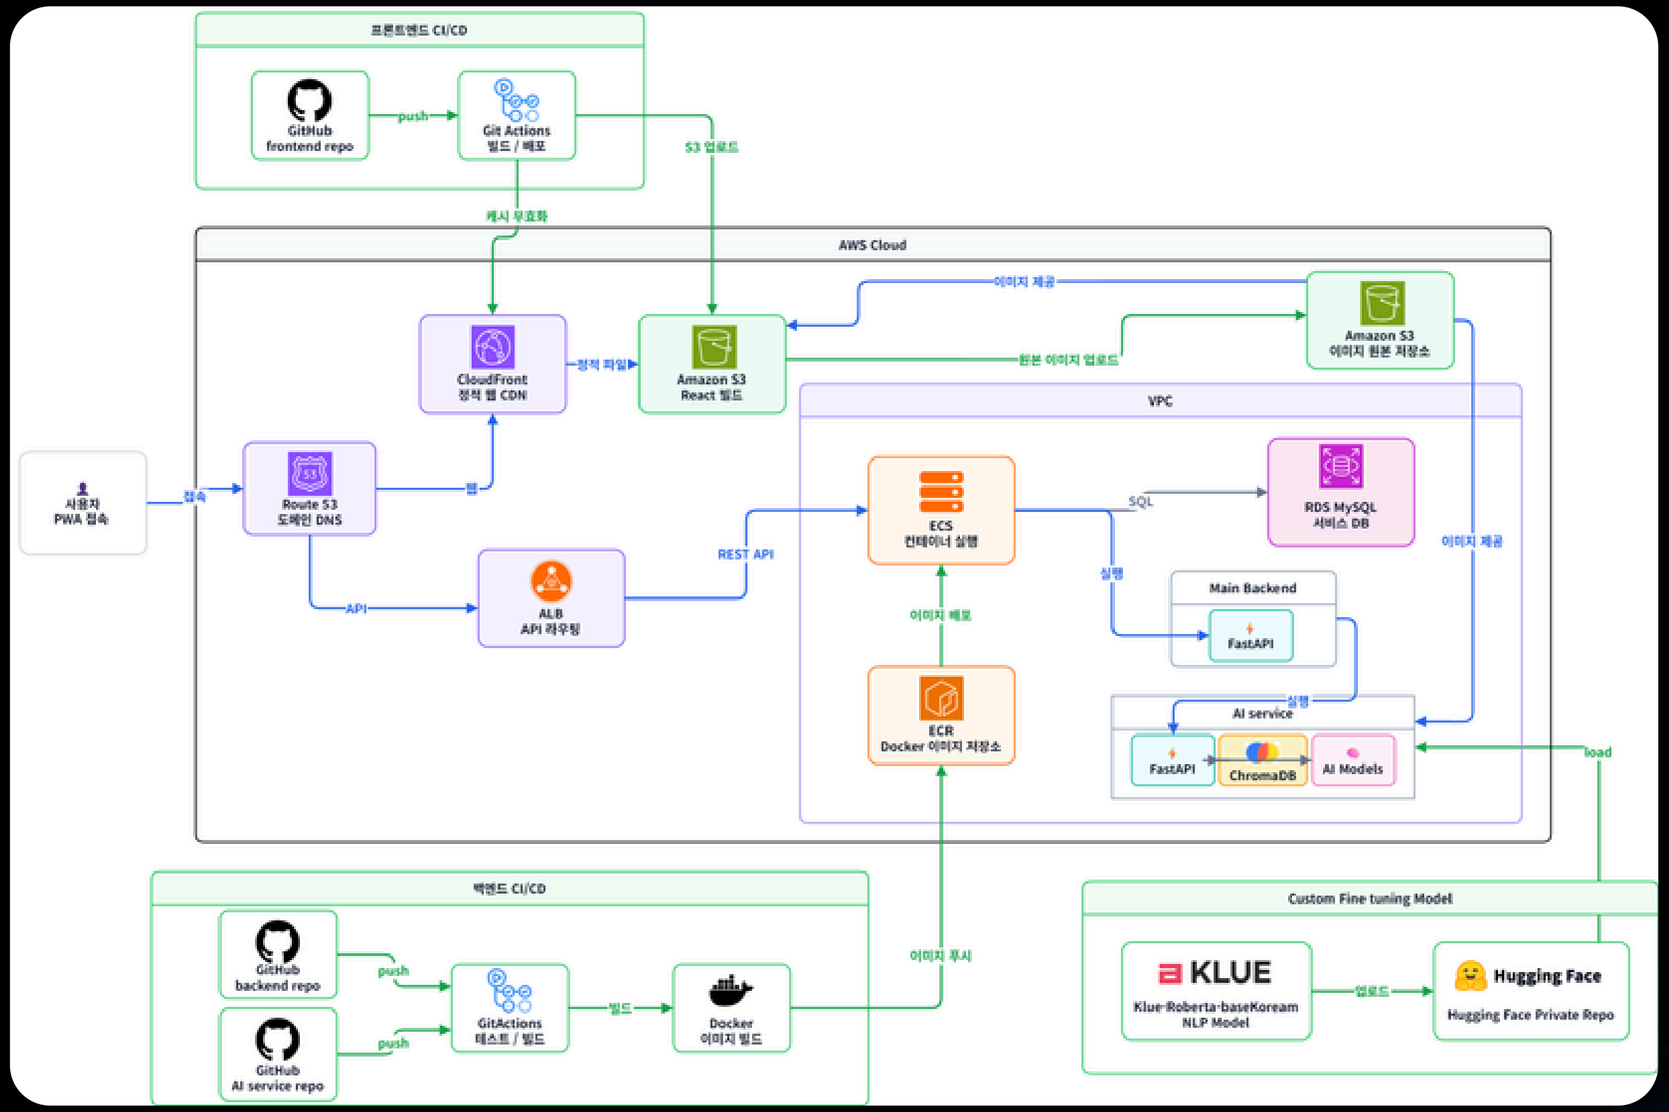

사용자 접속 및 트래픽 라우팅
AWS Route 53 & CloudFront

이미지 원본 저장 및 URL 주소 통신
Amazon S3

프론트엔드 CI/CD 자동화 파이프라인
GitHub Actions & Amazon S3

컨테이너 기반 백엔드 CI/CD 배포
Docker & AWS ECR/ECS

VPC 내 백엔드 & AI 마이크로서비스 연동
FastAPI, RDS & 외부 API

커스텀 AI 모델 파이프라인 및 서빙
Hugging Face & ChromaDB

Main Technology

AI 자동 견적 서비스

LangGraph & Vision LLM 기반

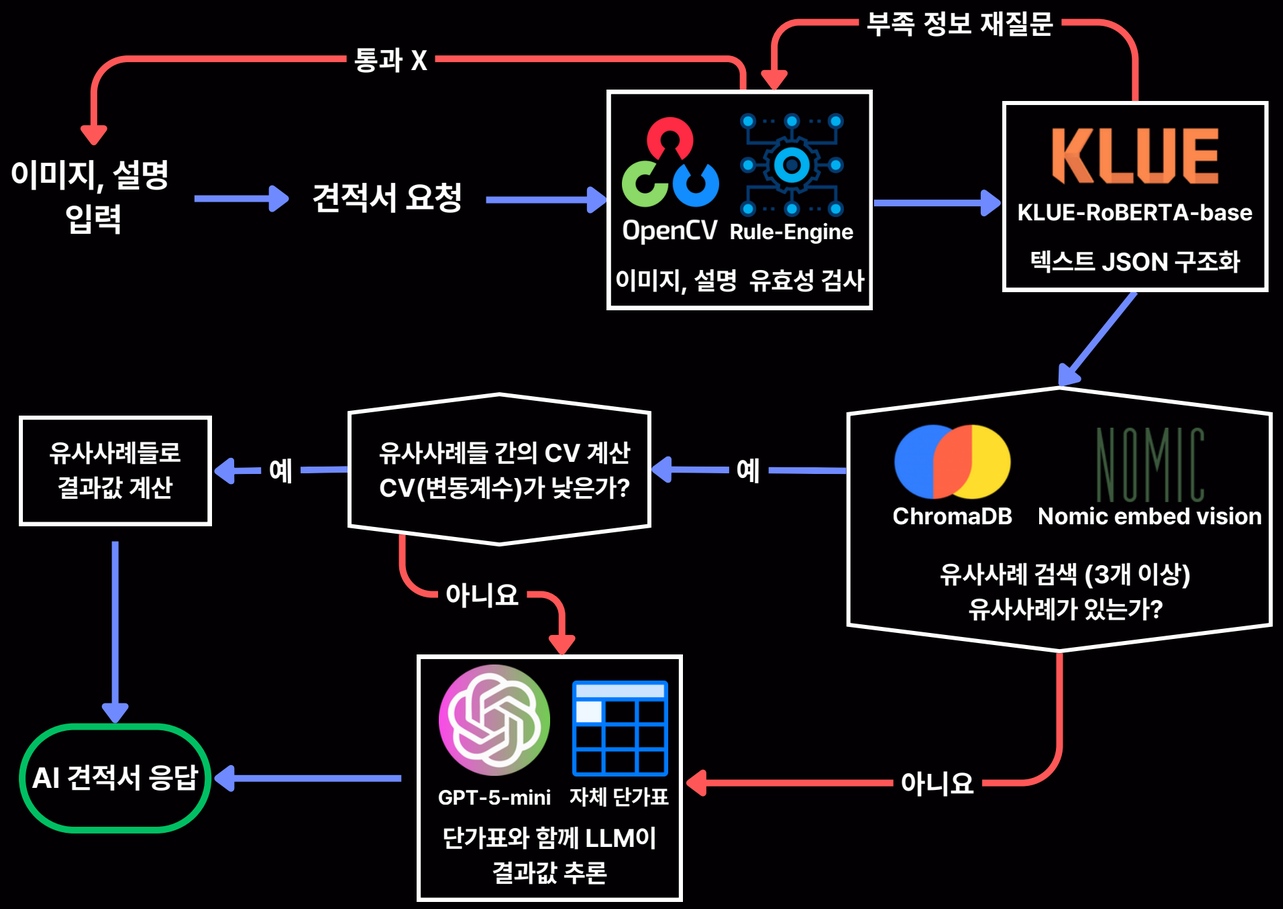

01

LangGraph 상태 관리

LangGraph
분기, 롤백, 루프 관리
품질 검증, 예외 처리, 추가 기재
각 단계와 연결 → 그래프 엣지와 노드

02

사진, 설명 유효성 검사

OpenCV, Rule-Engine
사진 조도·파손 식별 가능 여부 검사
설명 텍스트의 유효성 검사

03

텍스트 JSON 구조화

KLUE-RoBERTA (fine-tuning NLP)
설명 데이터 구조화
설명이 부족한 부분 검토 후 추가 기재
구조화 결과를 임베딩 메타데이터로 사용

04

유사 사례 분석

메타데이터를 이용해 유사사례 검색
+
이미지가 필수적인 일부 카테고리에만
이미지 → Nomic 모델 임베딩
코사인 유사도 분석

05

Vision LLM & 단가표

신규 파손 케이스의 이미지 정밀 분석
DB 통합 단가표
고정밀 견적 자동 생성
단가표는 매칭 종료시마다 갱신

Main Technology

AI 자동 견적 서비스

LangGraph & Vision LLM 기반

사용자 입력

“싱크대에서 물이 새요”

main_category	주방|배관/누수
object_label	싱크대
problem_label	누수
repair_task	싱크대 하부 누수 점검
missing_info	누수 위치|발생 시점
validity_label	valid_repair_request

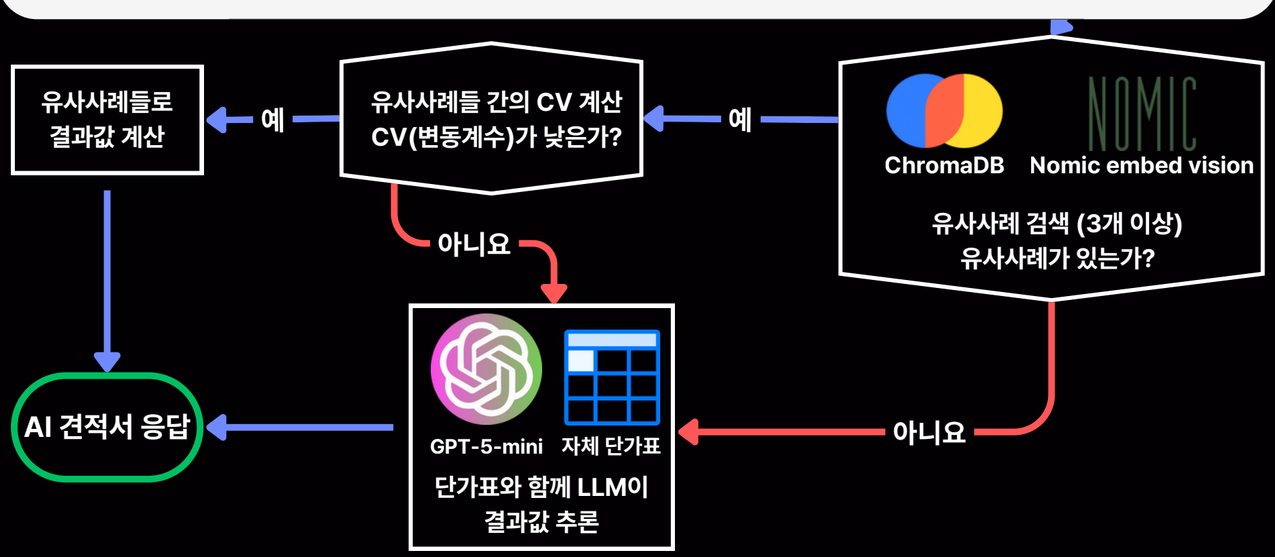

01

LangGraph 상태 관리

LangGraph
분기, 롤백, 루프 관리
품질 검증, 예외 처리, 추가 기재
각 단계와 연결 → 그래프 엣지와 노드

02

사진, 설명 유효성 검사

OpenCV, Rule-Engine
사진 조도·파손 식별 가능 여부 검사
설명 텍스트의 유효성 검사

03

텍스트 JSON 구조화

KLUE-RoBERTA (fine-tuning NLP)
설명 데이터 구조화
설명이 부족한 부분 검토 후 추가 기재
구조화 결과를 임베딩 메타데이터로 사용

04

유사 사례 분석

메타데이터를 이용해 유사사례 검색
+
이미지가 필수적인 일부 카테고리에만
이미지 → Nomic 모델 임베딩
코사인 유사도 분석

05

Vision LLM & 단가표

신규 파손 케이스의 이미지 정밀 분석
DB 통합 단가표
고정밀 견적 자동 생성
단가표는 매칭 종료시마다 갱신

Main Technology

AI 자동 견적 서비스

LangGraph & Vision LLM 기반

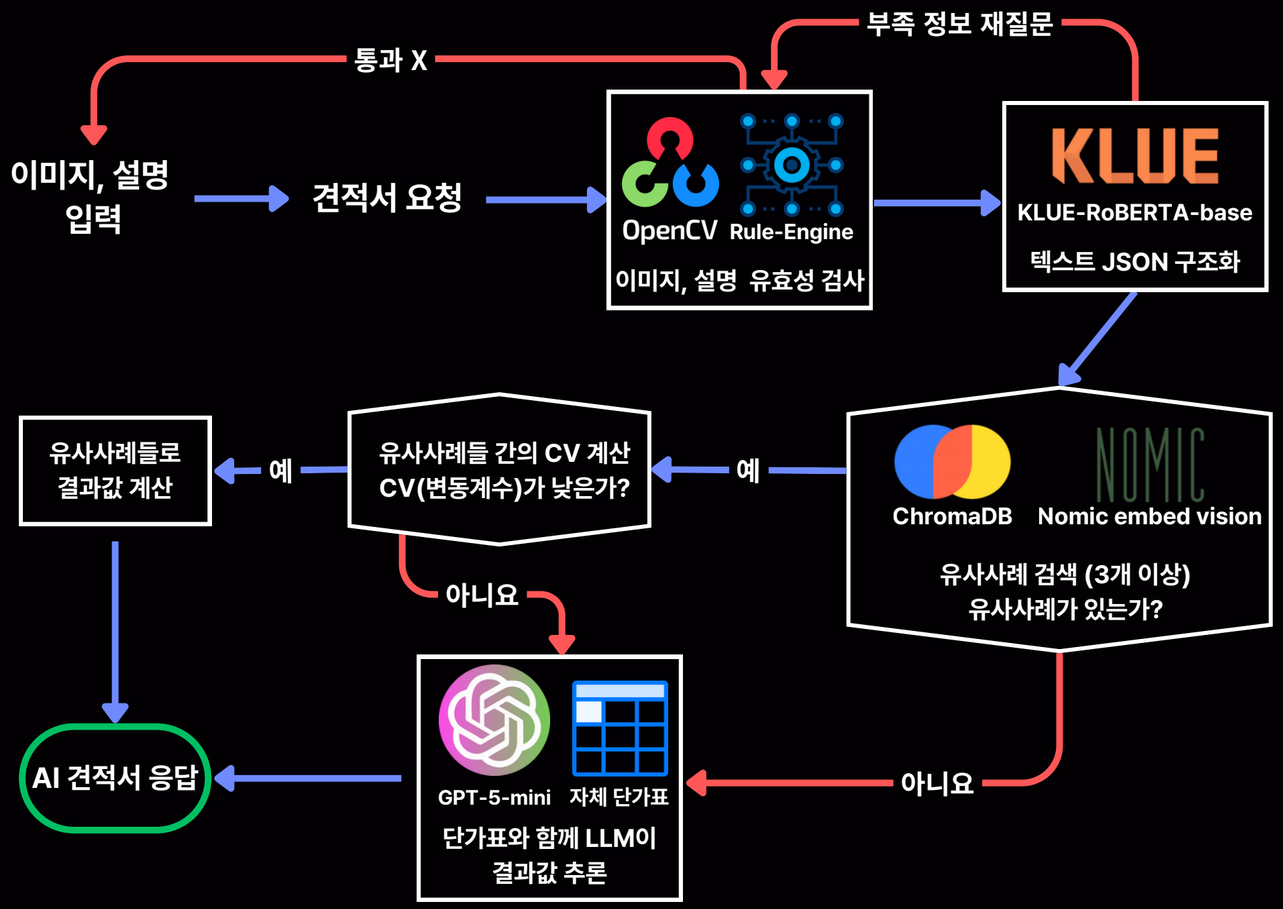

01

LangGraph 상태 관리

LangGraph
분기, 롤백, 루프 관리
품질 검증, 예외 처리, 추가 기재
각 단계와 연결 → 그래프 엣지와 노드

02

사진, 설명 유효성 검사

OpenCV, Rule-Engine
사진 조도·파손 식별 가능 여부 검사
설명 텍스트의 유효성 검사

03

텍스트 JSON 구조화

KLUE-RoBERTA (fine-tuning NLP)
설명 데이터 구조화
설명이 부족한 부분 검토 후 추가 기재
구조화 결과를 임베딩 메타데이터로 사용

04

유사 사례 분석

메타데이터를 이용해 유사사례 검색
+
이미지가 필수적인 일부 카테고리에만
이미지 → Nomic 모델 임베딩
코사인 유사도 분석

05

Vision LLM & 단가표

신규 파손 케이스의 이미지 정밀 분석
DB 통합 단가표
고정밀 견적 자동 생성
단가표는 매칭 종료시마다 갱신

Main Technology

AI 리스크리포트 서비스

LangChain & RAG 기반 지능형

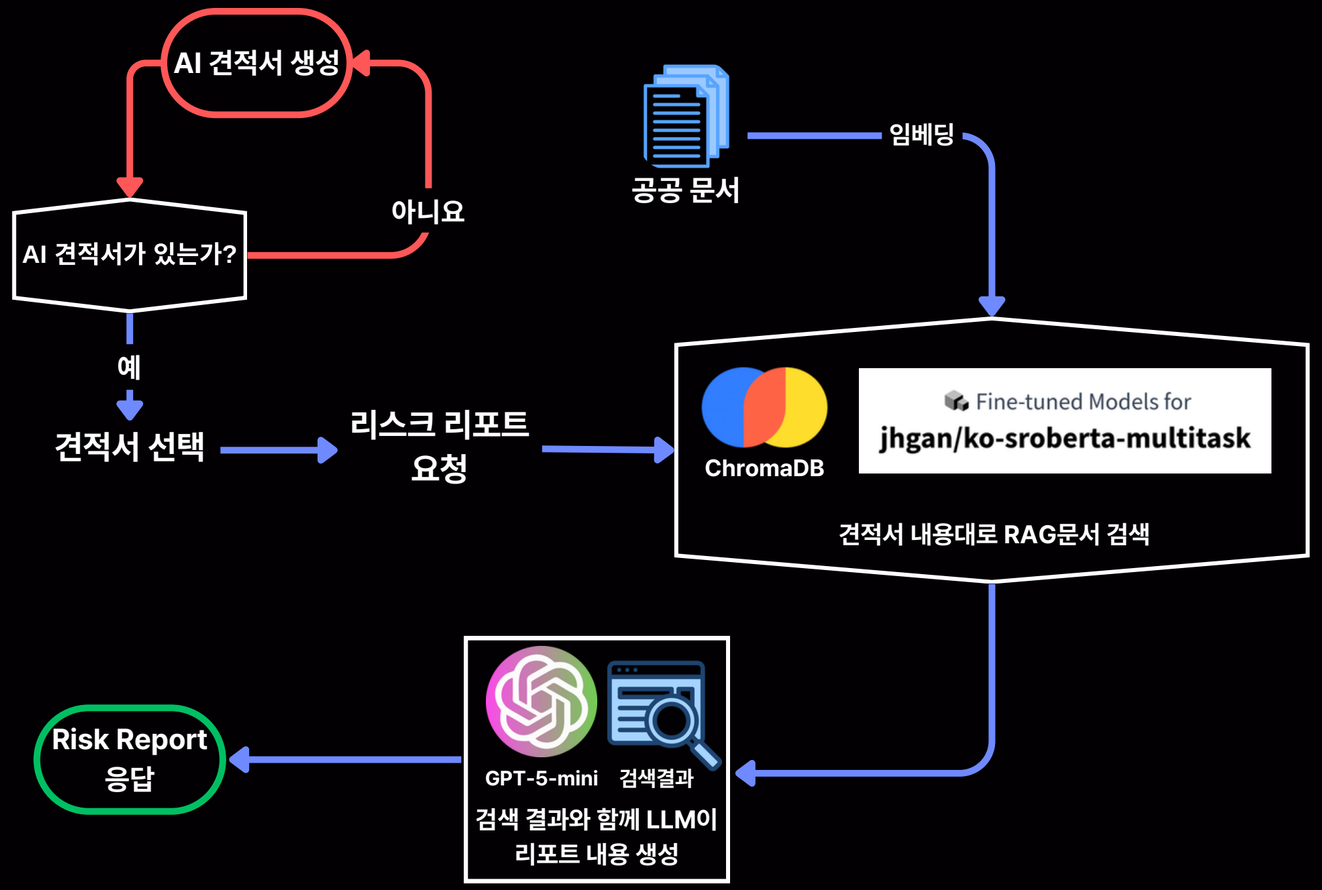

01

LangChain - RAG

LangChain
Ko-SRoBERTa, LLM
한국어 최적화 RAG 플로우 구성

02

임베딩 모델 커스텀

Ko-SRoBERTa (한국어용 모델)
기존의 LangChain 임베딩
모델보다 뛰어난 모델 채용

03

공인 문서 활용

소비자원 피해사례(Q&A),
공정위 표준계약서 등 벡터화
ChromaDB 임베딩 / 검색

04

AI 견적서 → 리포팅

추가 입력 X → 생성된 AI 견적서 사용
개별 공사 건별 맞춤형
하자·분쟁·안전 예방 리포트 출력

Main Technology

역경매 매칭 서비스

FastAPI & 위치 기반 API 중심 스마트

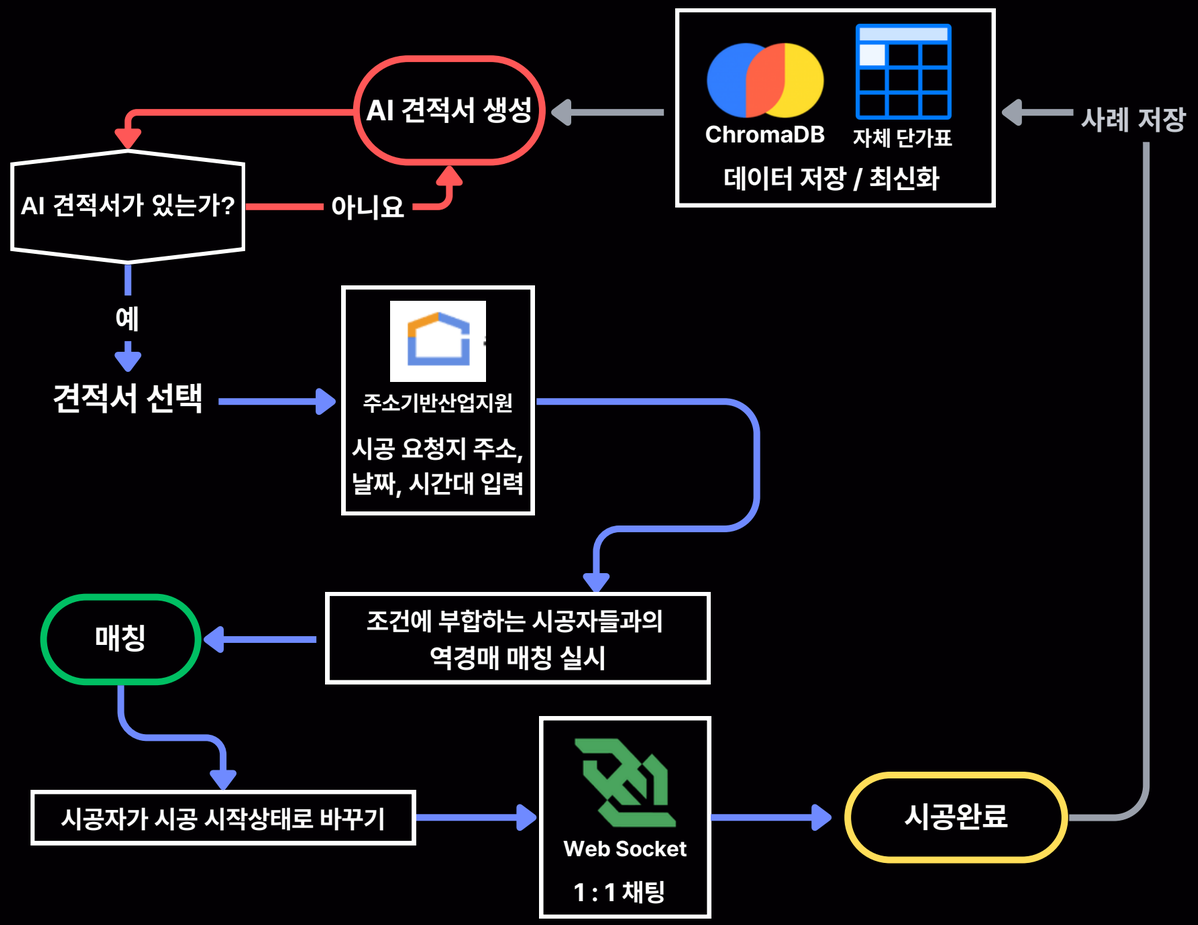

01

주소 API 연동

주소기반산업지원서비스 API
시공 위치 좌표 + 시공자 활동지역
→ 최적 후보 시공자 자동 필터링

02

매칭 상태 무결성 유지

Row Lock (Pessimistic Locking)
DB 트랜잭션
이중 매칭 등의 오작동 원천 차단
상태 무결성 확보

03

Notification 서비스

진행 상황 및 상태 변경 이벤트 감지
고객, 시공자에게 실시간 푸시 알림 발송

04

유사 사례 피드백

KLUE-RoBERTa
시공 데이터(사진 / 텍스트) 재임베딩
ChromaDB에 유사 사례 자가 저장
표준단가표 사례 반영 후 갱신

Validation

자연어 처리 모델 선정 과정

정량적 벤치마크 기반의 태스크별 최적 AI 모델(NLP·LLM) 선정 및 검증

KLUE-RoBERTa-base

- 한국어 특화 자연어 이해
- 문장 의미 분석, 분류 성능 높음

KoELECTRA

- 한국어 데이터 학습, 경량 모델
- 빠른 추론, 높은 분류 성능

KoT5

- 입력 문장 → 새로운 문장 생성
- 생성형 한국어 모델

Qwen2.5-Instruct

- 지시문 이해
- 답변을 학습한 LLM

EXAONE-Instruct

- 한국어, 영어 성능 우수
- 복잡한 추론·생성 능력의 LLM

01

기본 수행능력 평가 (5개 → 3개)

출력 성공률·형식 준수율·라벨 범주 준수율·처리 시간을
5개 모델 전부 확인

제외
- KoT5 (동일 토큰 반복하는 퇴행적 생성)
- EXAONE-Instruct (로컬 환경 추론 불안정)

02

구조화 정확도 평가 (3개 → 2개)

필드별 Accuracy·Macro·F1 Exact Match(전체 필드 일치율)를
3개 모델로 비교

제외
- Qwen2.5 (Exact Match 0%, 처리 지연 큼)

03

예외 케이스 평가 (2개 유지)

모호한 입력·가격 질문·위험 요청·정보 부족 등 실전 케이스로
KLUE-KoELECTRA 검증

추가 제외 없음
— 단, 둘 다 price_only·unsafe_input 탐지가 약함을 확인

Canva

Validation

자연어 처리 모델 선정 과정

정량적 벤치마크 기반의 태스크별 최적 AI 모델(NLP·LLM) 선정 및 검증

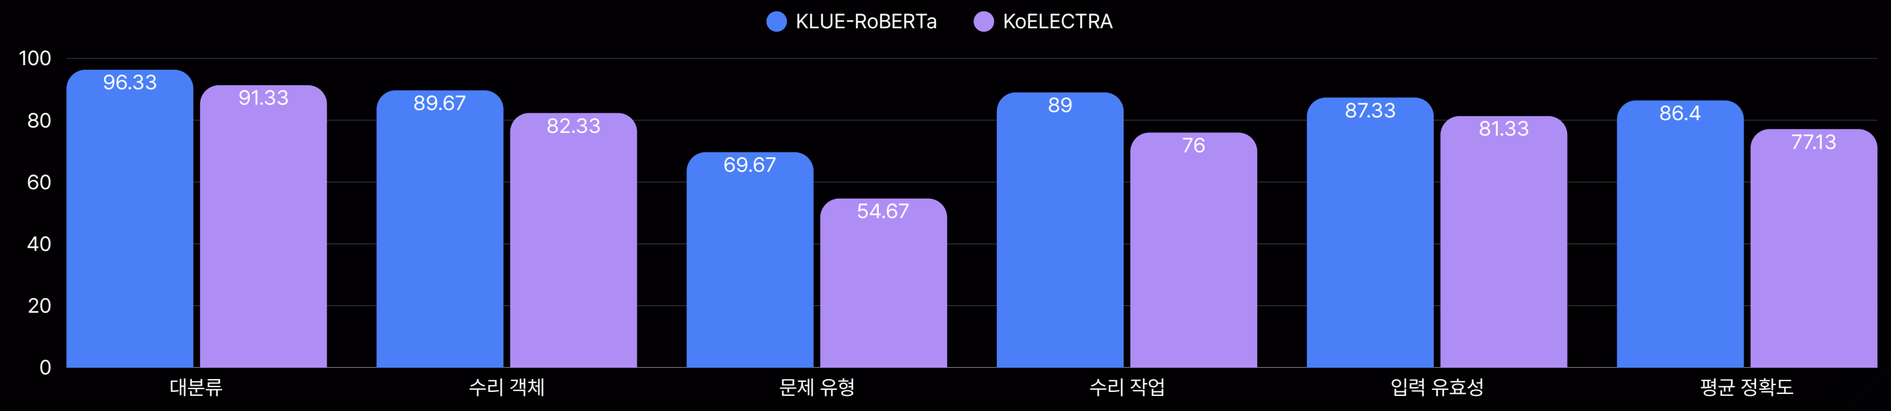

최종 선정 모델: KLUE-RoBERTa-base

- 전 영역 우월한 정확도: 5개 전 필드에서 경쟁 모델(KOELECTRA) 대비 우수한 성능을 기록하며 평균 정확도 86.4% 달성
- 초고속 실시간 추론: 건당 0.014초(14ms)의 빠른 처리 속도로 실시간 서비스 서빙 환경에 최적화
- LLM 대비 월등한 효율성: Prompt 기반 LLM(Qwen2.5)의 높은 지연 시간(27.7초) 및 높은 에러율 대비 비약적인 안정성·속도 확보

Validation

LLM 모델 선정 과정

정량적 벤치마크 기반의 태스크별 최적 AI 모델(NLP·LLM) 선정 및 검증

자체 배포 기준	월 비용	GPT-5 mini 대비 손익분기 요청 수
g6.xlarge	$587.50	약 258,000건/월
g5.xlarge	$734.38	약 323,000건/월
g6e.xlarge	$1,358.53	약 597,000건/월
g5.12xlarge	$4,140.56	약 1,820,000건/월

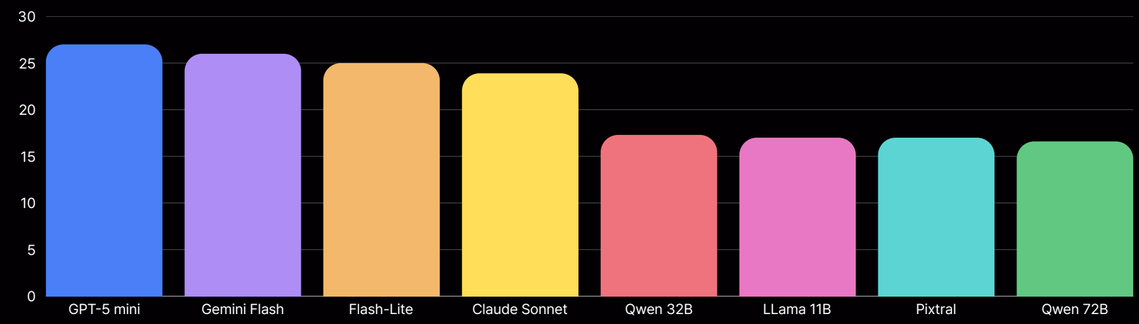

최종 선정 모델: GPT-5 mini

- 정확한 구조화 (Structured Outputs): 견적서 필수 포맷(JSON Key/Value) 누락 및 형식 오류 재시도 비용을 최소화
- 압도적인 경제성: 월 10,000건 생성 기준 약 $22.75 (3만 원 대)로 초기 서비스 운영 리스크 최소화
- 멀티모달 통합: 시공 현장 이미지 분석과 단가표 매칭을 단일 API 요청으로 안정적으로 처리

Validation

이 외 시행한 성능평가

최적의 성능과 비용을 끌어내기 위한 다양한 성능평가 시행

01

텍스트 유효성 검사 (Rule-Engine)

- 선정 모델: **규칙 기반 가중치 Scoring** (증상 가중치 2.5 우선 적용)
- 핵심 성과: 비정상 문장(욕설·스팸·범위 밖) **오통과율 0.00%** (**전체 정확도 93.21%**)
- 주요 역할: NLP 단계 진입 전, 무의미하거나 위험한 텍스트 입력을 즉시 차단하는 **1차 안전 필터**

02

이미지 유사사례 검색 (Nomic Embed Vision)

- 선정 모델: **Nomic Embed Vision v1.5 + Cosine Similarity**
- 핵심 성과: **오답 통과 0개** 기준 충족 및 **정답 통과율 전체 1위** (60.4%)
- 주요 역할: 카테고리별 맞춤 Threshold를 적용해 기존 **사례를 캐싱**함으로써 **LLM 비용 절감**

03

사진 품질 검사 (OpenCV Baseline)

- 선정 모델: **OpenCV Rule-based** (Laplacian Blur & Max Exposure)
- 핵심 성과: 실사 데이터 검증 우수 (ROC-AUC 0.790), 처리 속도 15ms, **인프라 비용 $0**
- 주요 역할: 어둡거나 흔들린 사진을 Vision LLM 전달 전에 **사전 감지**하여 재촬영 유도

04

RAG AI 모델 (Jhgan/Ko-SRoBERTa & GPT-5 mini)

- 선정 모델: Ko-SRoBERTa (NLP) + **GPT-5 mini** (Vision LLM)
- 핵심 성과: NLP 5개 필드 **평균 정확도 86.4%** / **LLM 적합도 1위** (27.0점, 월 $22.75)
- 주요 역할: 수리 요청 문맥의 정밀 구조화 및 **고정밀·저비용 AI 자동 견적서** 산출

04 비즈니스 모델

수익 구조 · 확장성

TUKTAK

Business

고객 무료 이용 + 시공 성사 수수료 기반 수익 구조

견적 이용료와 시공 수수료, 두 지점에서 수익이 발생합니다

고객 (AI 견적서) → 매칭 성사 → 시공 완료 → 시공 대금 결제

고객 — 견적 이용 정책 (토큰 & 구독제)

- AI 견적서 하루 3회까지 무료 제공
- 3회 초과 시 횟수권 구매로 이용
- 오피스텔·다가구 주택 등은 월 정액 구독제로 별도 운영

시공자 — 매칭 수수료 정책 (수수료 차감)

- 시공 금액 20만원 이하: 금액의 5%
- 시공 금액 20만원 초과: 고정 10,000원

05 트러블 슈팅

문제 상황 · 해결 과정

TUKTAK

Solution

개발·운영 중 발생한 이슈와 해결 방안

문제를 정확히 정의하고, 체계적으로 해결하여 더 안정적인 서비스를 제공합니다.

문제 1

프로젝트 관리 툴 변경

Notion을 이용한 기록식 프로젝트 관리의 한계로 산출물/일정/작업 분배의 수행이 비효율적

Jira 프로젝트 관리 소프트웨어 연동 & 사용
효율적인 실무에 가까운 프로젝트 관리

문제 2

AI 모델 배포 과부하

Fine-Tuning Model 배포 문제

Hugging Face repo 생성/활용

문제 3

RAG 검색 품질 저하

LangChain 기본 임베딩 모델 사용 시 리스크 문서 검색 결과 부정확

임베딩 모델 성능평가를 직접 진행해 Ko-SRoBERTa 모델로 교체 적용

06 향후 계획

전망 · 확장 계획

TUKTAK

Business

더 나은 집수리 경험을 위해, 지속적으로 확장해 나가겠습니다

더 편하게, 더 믿을 수 있게 — 서비스가 한 단계씩 완성됩니다

서비스 고도화

01

견적 비교 고도화

가격·일정·평점·리스크 항목을
한눈에 비교할 수 있는 스마트 견적 비교 제공

기대효과: 견적 비교 시간 단축

02

SNS 로그인 연동

카카오·네이버·구글 간편 가입으로
회원 가입과 로그인을 더 빠르고 편리하게

기대효과: 가입 이탈률 감소

03

시공자 자격 인증

자격증·사업자등록증 등록으로
시공자의 신뢰도와 전문성을 강화

기대효과: 매칭 신뢰도 상승

기능 하나하나가 쌓여 더 빠르고, 더 편하고, 더 믿을 수 있는 서비스가 됩니다.

Business

더 나은 집수리 경험을 위해, 지속적으로 확장해 나가겠습니다

데이터가 쌓일수록, 우리만의 모델로 나아갑니다

AI 고도화

현재

API 토큰 기반 운영

초기에는 외부 LLM API를 호출하는 방식으로 빠르게 서비스를 검증하고,
견적·리스크 리포트 데이터를 축적합니다.
초기 개발 리소스를 서비스 검증에 집중할 수 있습니다.

향후

자체 모델 파인튜닝 & 서버 운영

고객·시공 데이터가 충분히 쌓이면,
오픈소스 LLM을 파인튜닝해 자체 서버에서 운영하여 비용을 절감하고
TukTak 도메인에 특화된 정확도를 확보합니다.

데이터 축적

견적·리스크 리포트·매칭 데이터 확보

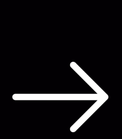

파인튜닝

오픈소스 LLM을 TukTak 도메인에 특화

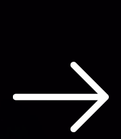

자체 호스팅 전환

트래픽 증가에 따라 토큰 비용 부담 절감

Business

더 나은 집수리 경험을 위해, 지속적으로 확장해 나가겠습니다

공급과 수요, 두 축을 동시에 키워야 하는 단계입니다

마케팅 필요

01

시공자 유치

초기 공급 확보를 위한 영업·마케팅 활동이 필요합니다.
공급이 부족하면 고객이 매칭 자체를 경험할 수 없습니다.

우선순위: 서비스 출시 직후 최우선

02

사용자 유치

서비스 인지도 확보를 위한 초기 마케팅 활동이 필요합니다.
시공자 공급이 갖춰진 이후 병행 확대합니다.

우선순위: 공급 확보 이후 병행

양면시장은 공급(시공자)이 먼저 갖춰져야 수요(고객)가 실제 매칭을 경험할 수 있습니다.

Team Q&A

팀장

백승우

프로젝트 관리 및 총괄
총 서비스 흐름 구조 설계
각 파트 기술 스택 선정 및 설계
API 명세 설계
ERD 설계 및 제작
CI/CD 파이프라인 설계 및 구현
메인 백엔드 구현 총괄
AI 서비스 전체 구조 설계
AI 서비스 구현 총괄
NLP 성능평가 설계 및 수행
각 AI 모델 성능평가 기획

데이터 모델링 담당 / 디자인 총괄

반고호

UI / UX 디자인 총괄
UI / UX 전체 디자인 구현
시공자 프로필 및 전문 분야
데이터 모델링 및 RESTful API 구현
OpenCV 성능평가 설계 및 수행
텍스트 유효성 검사 성능평가 설계 및 수행
서비스 아키텍쳐 작성
시연 영상 제작

데이터 모델링 담당

김지민

모델 학습용 더미 데이터 생성
사진 품질 검사 성능평가 및
후보 모델 선정
OpenCV 임계값(threshold) 설정
RAG 리스크 리포트 구현 설계 및
데이터 수집

AI 백엔드/RAG 구현 담당

전지원

Risk Report 도메인 모델 및 API 구현
AI Service 연동 구조 설계
이미지 유사사례 검색 Threshold 설계
Nomic Embed Vision 유사도 검색 구조 설계
ChromaDB 기반 RAG 검색 흐름 설계 및 구현
시연 영상 제작

허공답보

THANK YOU

모바일 TUKTAK 웹 앱에 접속해서 새로운 시공 문화를 만들어가요.

Tell
010-8626-1074

Email
swbaik01@gmail.com

Website
https://tuktakai.com

APPENDIX

TukTak Total Service Flow Architecture

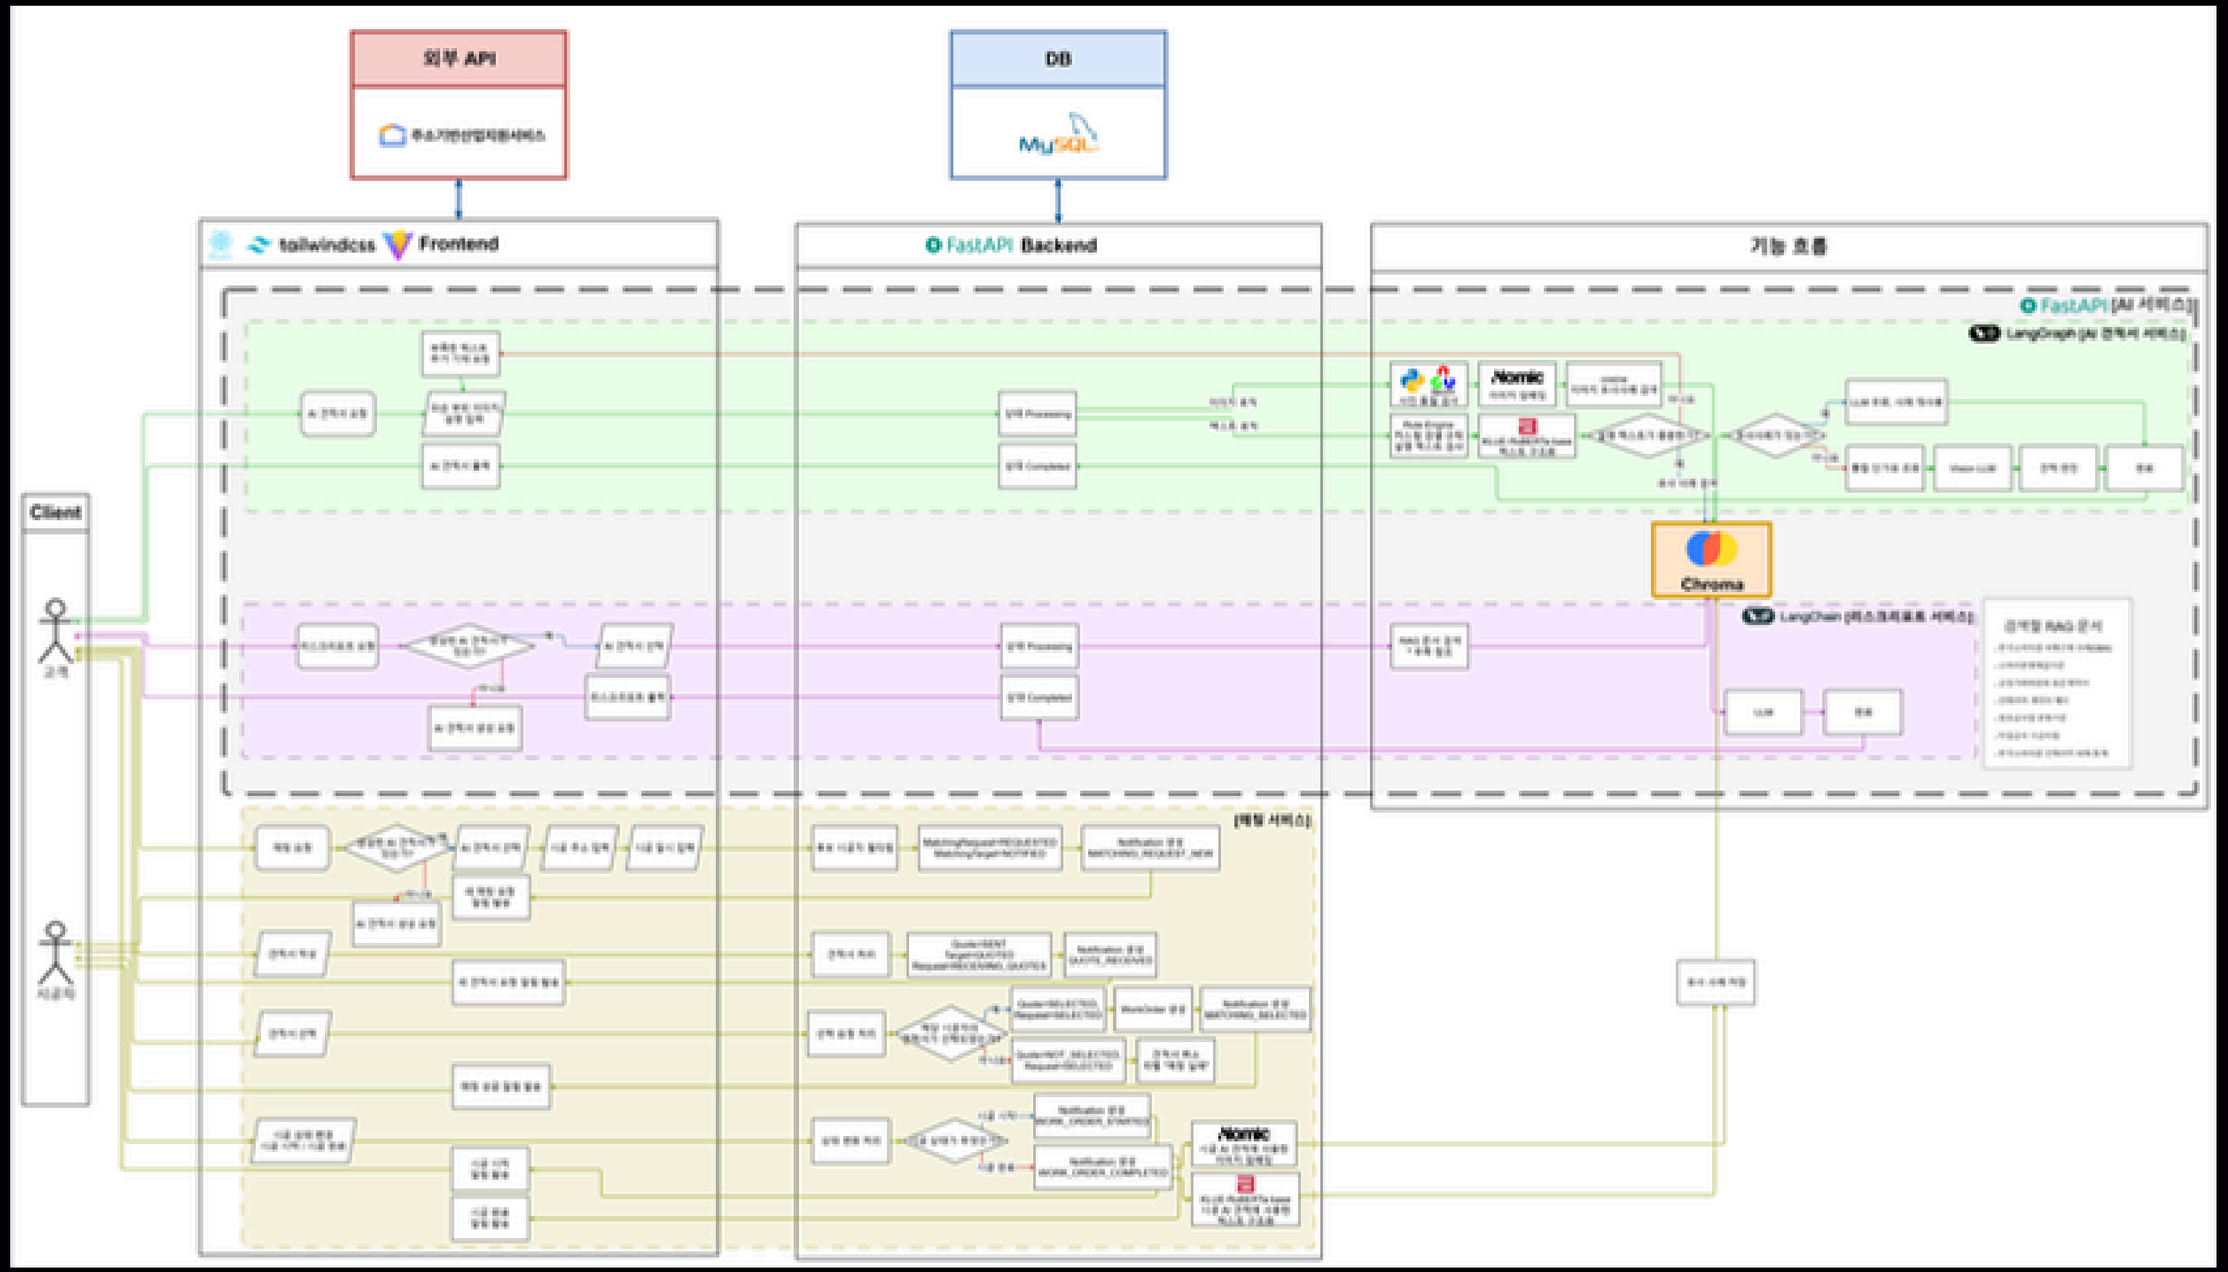

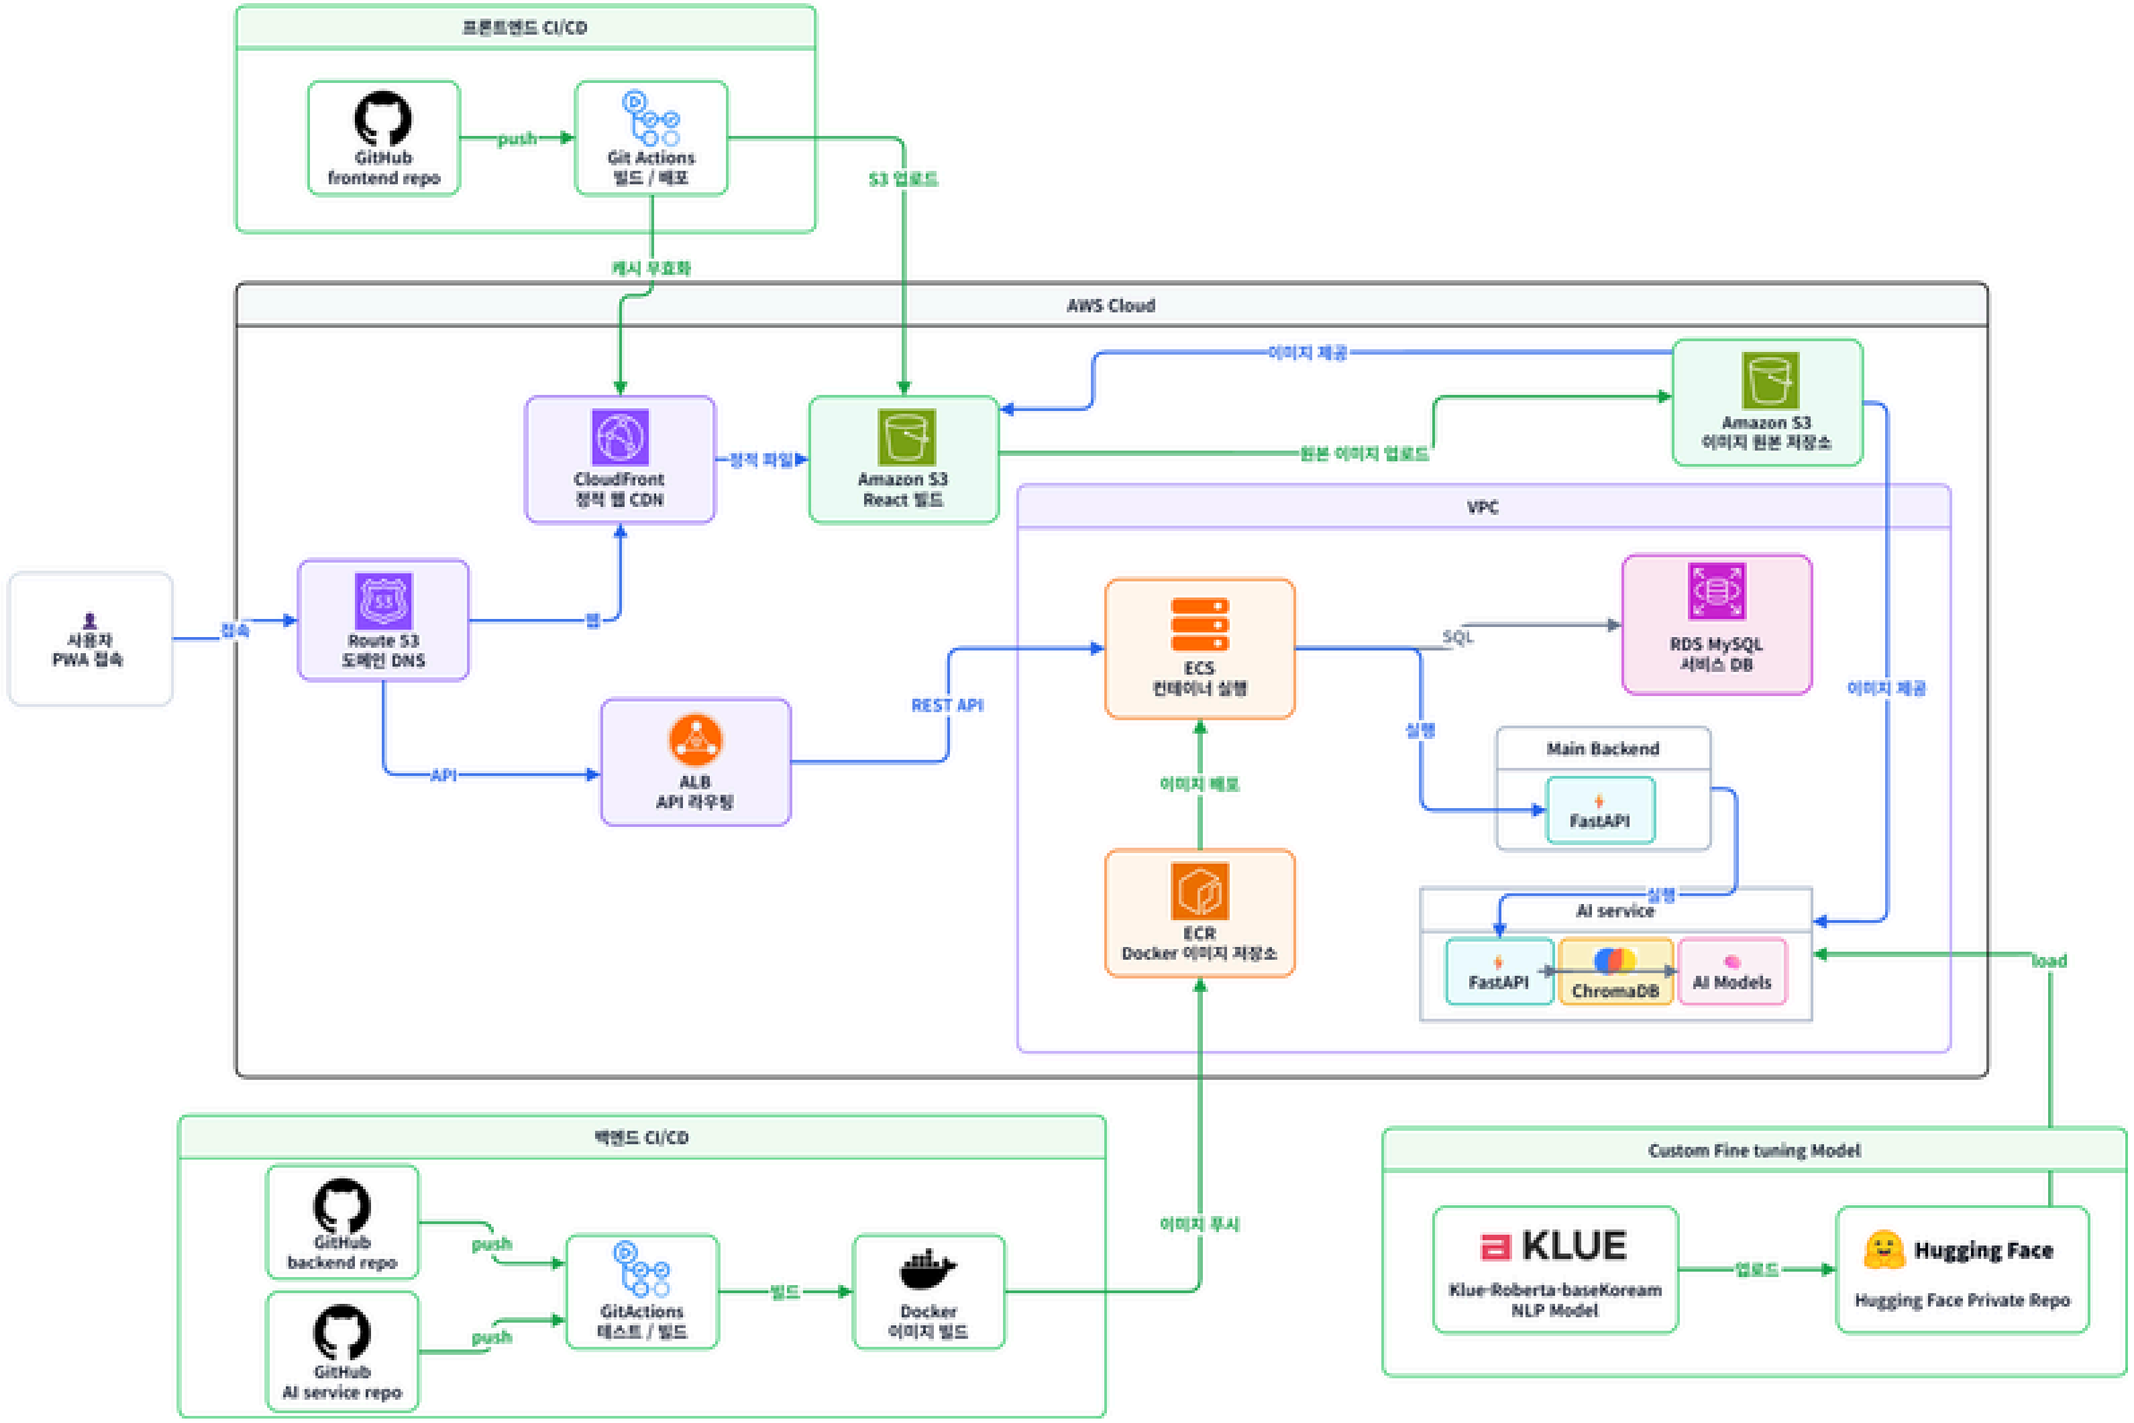
프론트엔드 CI/CD
GitHub
frontend repo
push
Git Actions
빌드 / 배포
S3 업로드
캐시 무효화
AWS Cloud
이미지 제공
Amazon S3
이미지 원본 저장소
원본 이미지 업로드
CloudFront
정적 웹 CDN
정적 파일
Amazon S3
React 빌드
VPC
사용자
PWA 접속
접속
Route 53
도메인 DNS
맵
ECS
컨테이너 실행
SQL
RDS MySQL
서비스 DB
이미지 제공
REST API
Main Backend
FastAPI
실행
API
ALB
API 라우팅
이미지 배포
ECR
Docker 이미지 저장소
실행
AI service
FastAPI
ChromaDB
AI Models
load
백엔드 CI/CD
GitHub
backend repo
push
GitHub
AI service repo
push
GitActions
테스트 / 빌드
빌드
Docker
이미지 빌드
이미지 푸시
Custom Fine tuning Model
KLUE
Klue-Roberta-baseKoream
NLP Model
업로드
Hugging Face
Hugging Face Private Repo

1차 기본 수행능력 평가

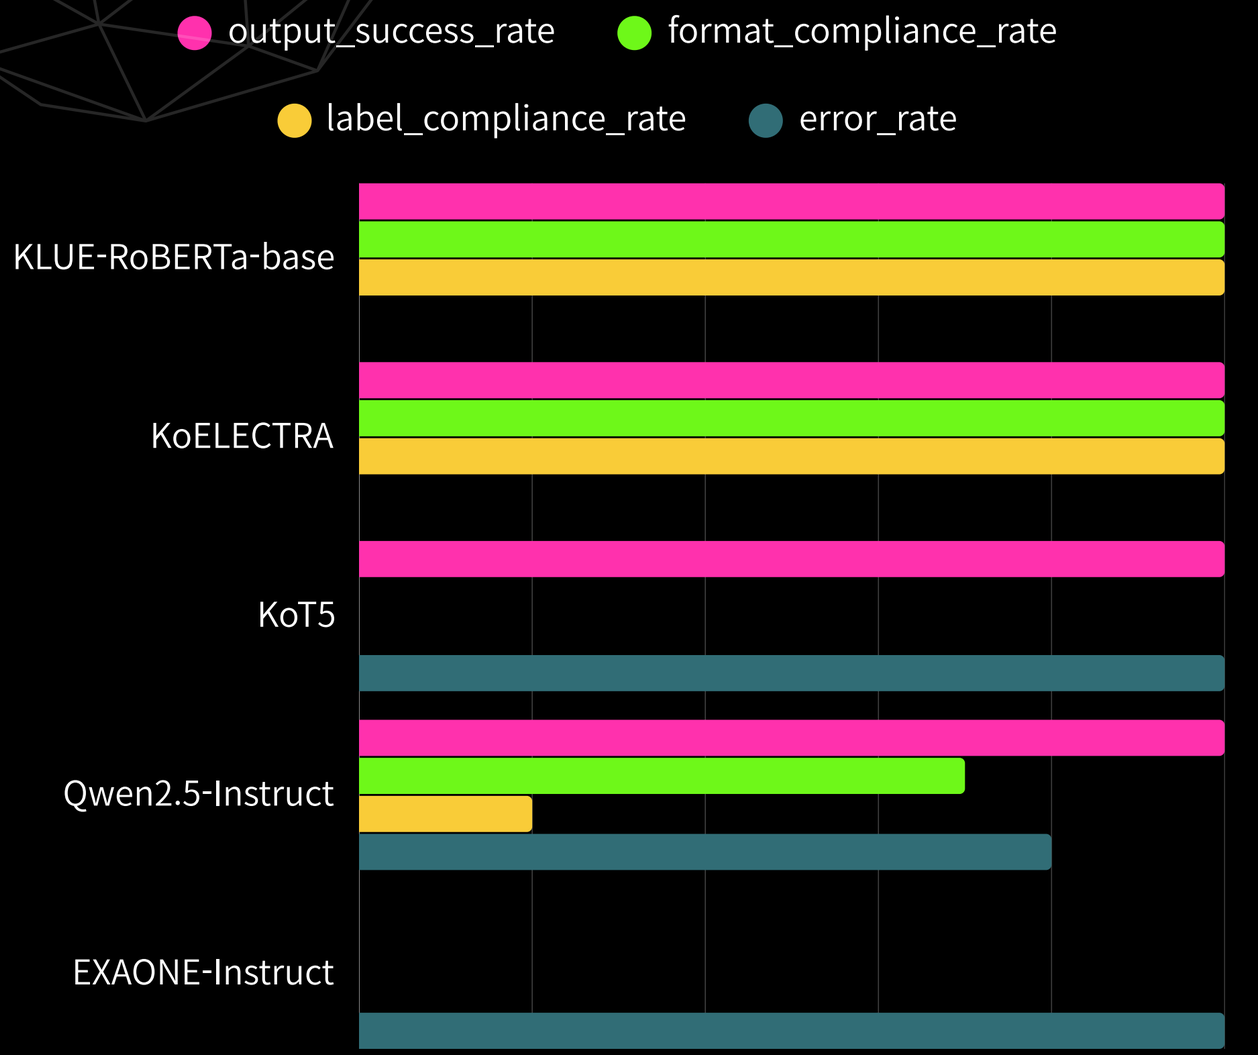

평가 모델 수
5

통과 모델 수
2

최고 라벨 준수율
100.0%

최단 평균 처리시간
0.011s

출력 성공률, 형식 준수율, 라벨 범주 준수율, 처리 시간 확인

1차 제외 모델

- KoT5
- EXAONE-Instruct

1차 유지 모델

- KLUE-RoBERTa-base
- KoELECTRA
- Qwen2.5-Instruct

2차 구조화 정확도 평가

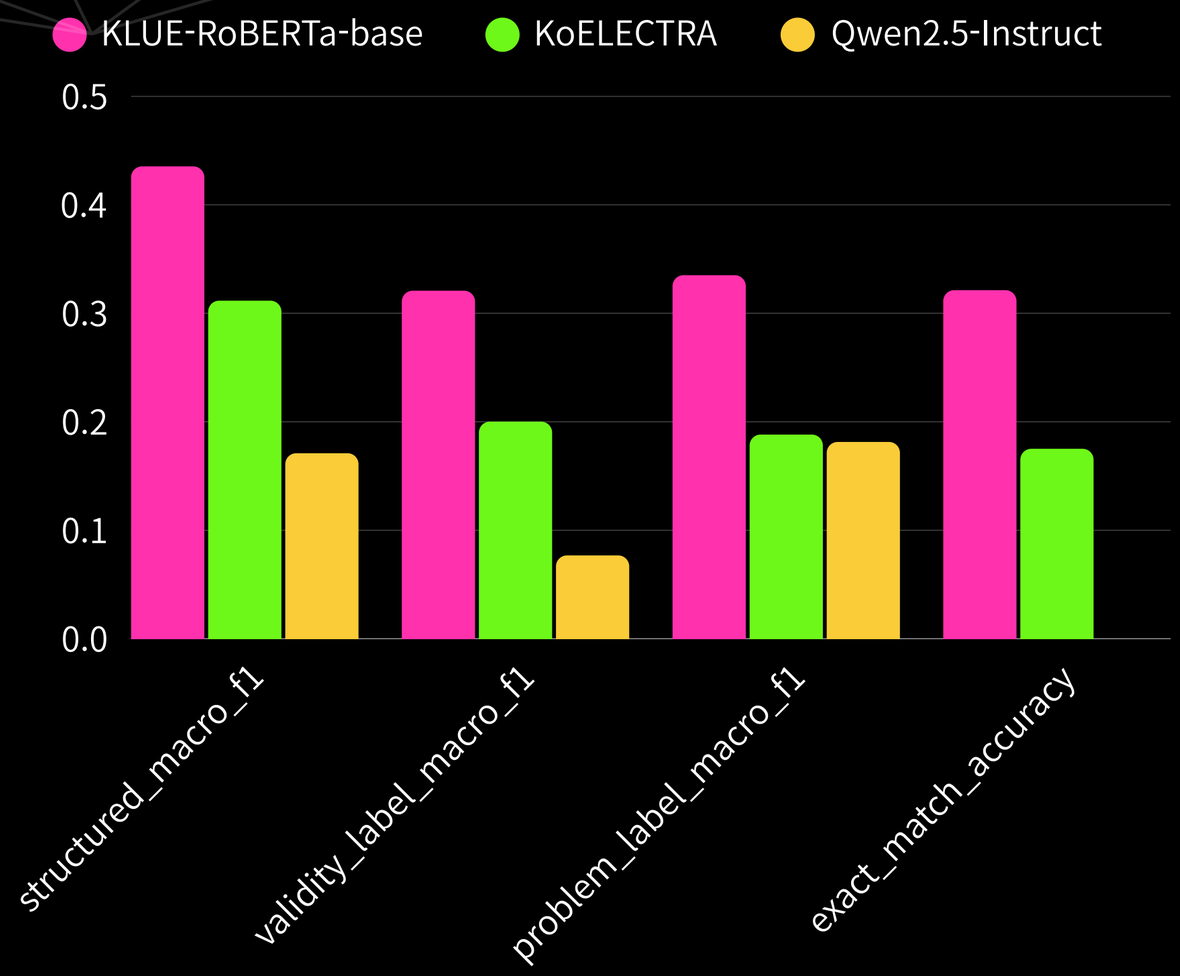

1위 모델
KLUE-RoBERTa-base

Structured Macro-F1
0.435

Exact Match
32.1%

평균 처리시간
0.012s

필드별 Accuracy, Macro-F1, missing_info 점수, Exact Match 비교

2차 제외 모델

- Qwen2.5-Instruct

2차 유지 모델

- KLUE-RoBERTa-base
- KoELECTRA

3차 예외 케이스 평가

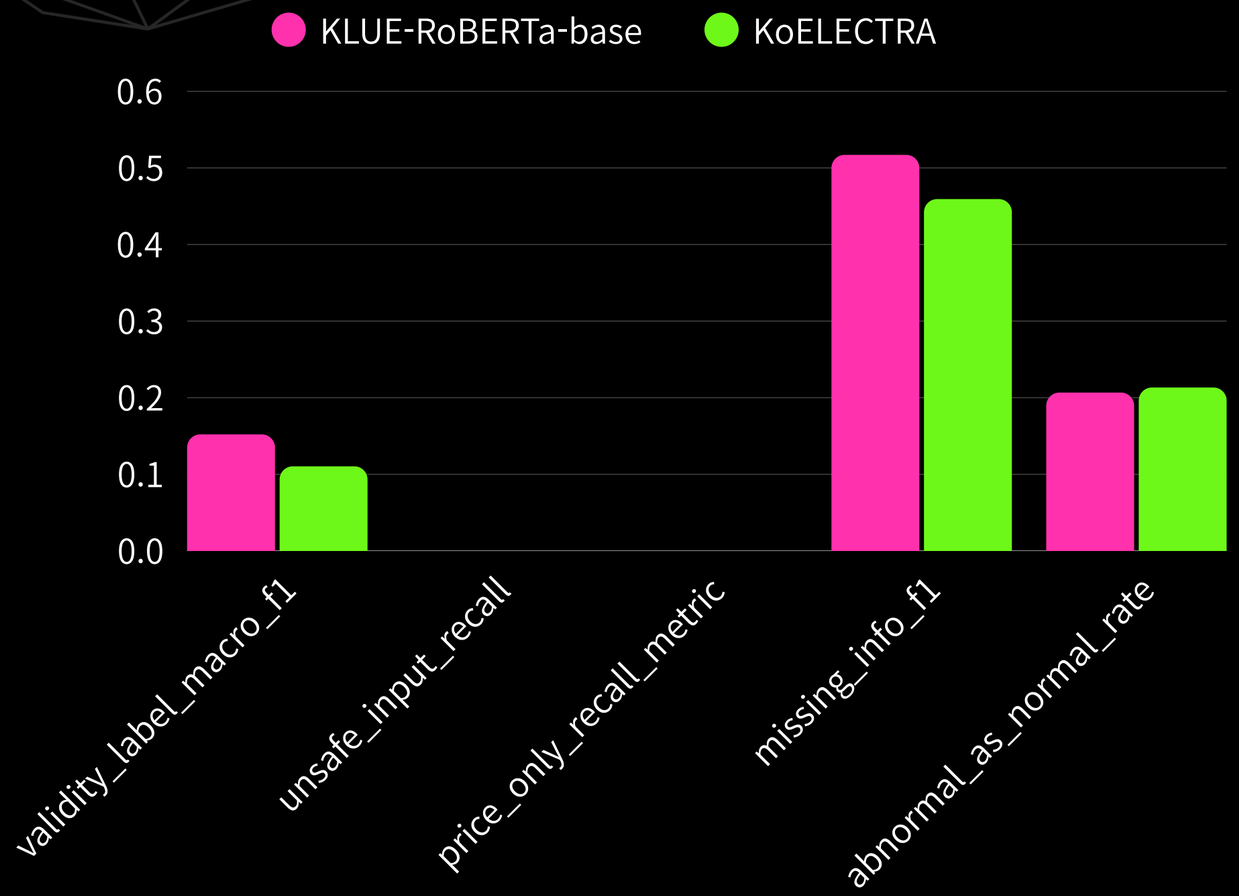

상대 우세 모델
KLUE-RoBERTa-base

Validity Macro-F1
0.152

비정상+정상 오분류
20.7%

Missing Info F1
0.517

모호한 입력, 가격 질문, 위험 요청, 정보 부적 입력 검증

3차 모델 판단

- 추가 제외 없음

서비스 보완 필요

- 룰 기반 pre-filter 추가 필요

4차 최종 서비스 적합성 평가 (1)

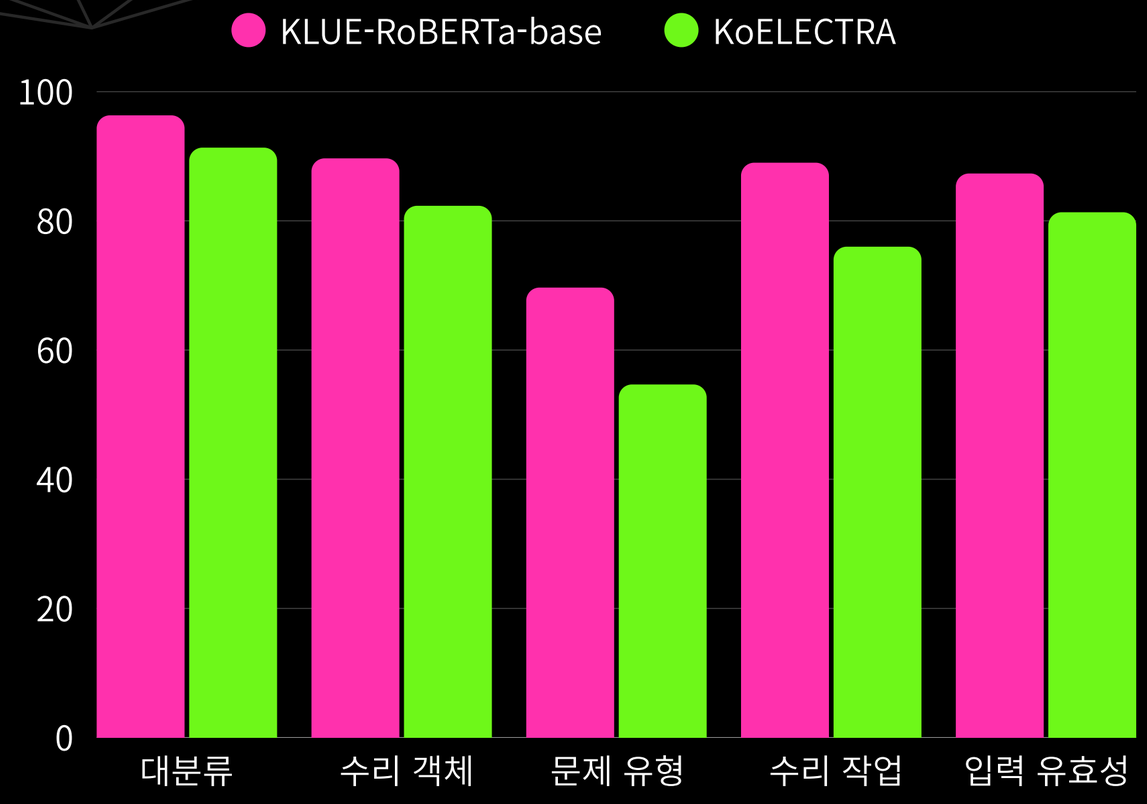

최종 1위
KLUE-RoBERTa-base

평균 정확도
86.4%

평균 처리시간
0.014s

missing_info를 제외한 5개 구조화 필드의 Accuracy 비교

최종 선정 판단

- KLUE-RoBERTa-base 선정

4차 최종 서비스 적합성 평가 (2)

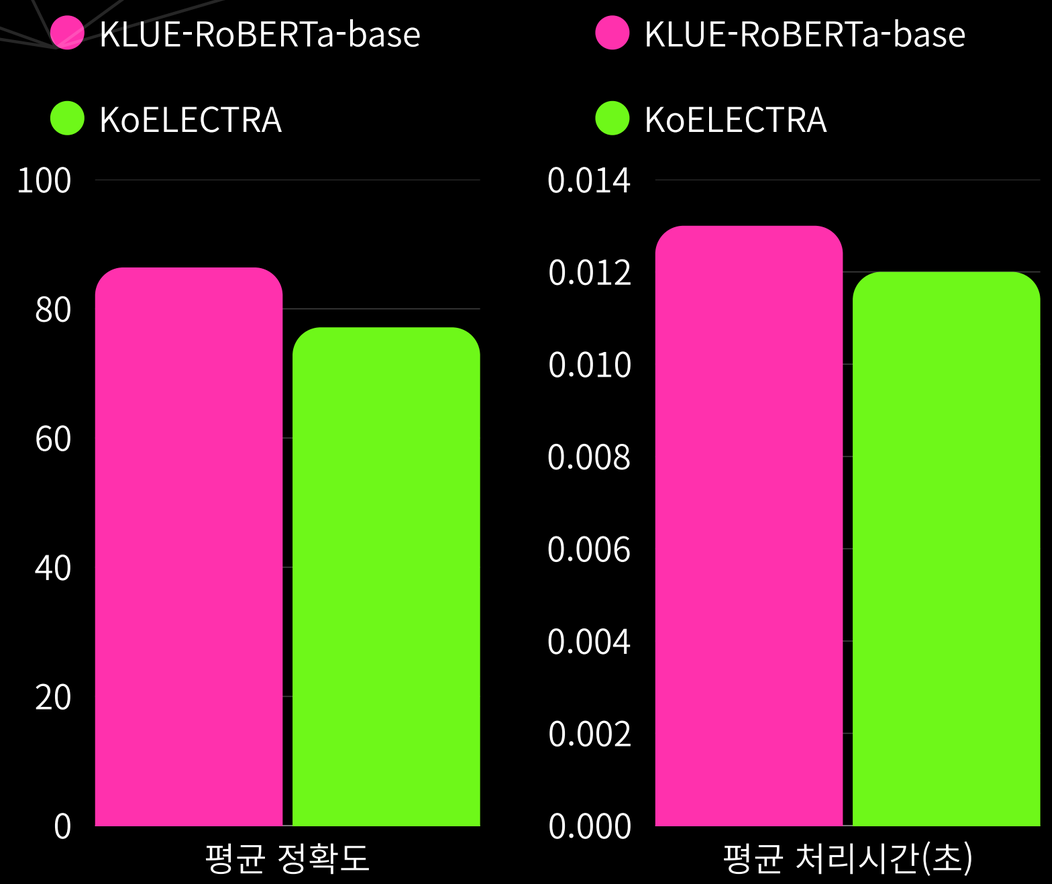

최종 1위
KLUE-RoBERTa-base

평균 정확도
86.4%

평균 처리시간
0.014s

missing_info를 제외한 5개 구조화 필드의 Accuracy 비교

최종 선정 판단

- KLUE-RoBERTa-base 선정

TUKTAK AI 견적서 생성 LLM 모델 선정 비교 보고서

작성일: 2026-07-20 | AI 견적서 최종 생성 단계에서 사용할 LLM을 비용, 지연시간, 운영 난이도, 완성도 기준으로 비교

2. 평가 전제

항목	값
텍스트 입력 토큰	3,500 tokens
출력 토큰	700 tokens
이미지	1장
입력 내용	원본 설명, 구조화 결과, 표준 단가표 해당 row, 유사사례 최대 3개, 이미지
월 요청량 비교 기준	10,000건
자체 GPU 서버 월 비용 기준	730시간 고정 운영

실제 API 과금에서 이미지는 모델별 내부 토큰/이미지 단가로 환산된다. 여기서는 공개된 입력/출력 토큰 단가로 단순 환산했으며, 운영 전에는 provider usage 로그로 재산정해야 한다.

3. API 모델 비용 비교

모델	입력 $/1M	출력 $/1M	1회 비용	월 10,000건	판단
Gemini 2.5 Flash-Lite	0.10	0.40	$0.00063	$6.30	최저비용. 품질 검증 필요
GPT-5 mini	0.25	2.00	$0.00228	$22.75	비용/품질/구조화 안정성 균형
Gemini 2.5 Flash	0.30	2.50	$0.00280	$28.00	빠른 멀티모달 후보
Claude Haiku 4.5	1.00	5.00	$0.00700	$70.00	저가 Claude 후보
Gemini 2.5 Pro	1.25	10.00	$0.01138	$113.75	고품질 Gemini 후보
Claude Sonnet 5 intro	2.00	10.00	$0.01400	$140.00	2026-08-31까지 intro 가격
Claude Sonnet 4.6 / Sonnet 5 standard	3.00	15.00	$0.02100	$210.00	고품질, 고비용

4. 자체 GPU 배포 모델 비용 비교

인스턴스	GPU	시간당 비용	월 730h 비용	적합 모델
g6.xlarge	1x NVIDIA L4 24GB	$0.8048/h	$587.50	경량/양자화 7B~12B
g5.xlarge	1x NVIDIA A10G 24GB	$1.006/h	$734.38	Llama 3.2 11B Vision, Pixtral 12B
g6e.xlarge	1x NVIDIA L40S 48GB	$1.861/h	$1,358.53	32B급 4bit 실험
g5.12xlarge	4x NVIDIA A10G 24GB	$5.672/h	$4,140.56	Qwen 32B 여유 운영, 72B 4bit 실험
g6e.12xlarge	4x NVIDIA L40S 48GB	$10.493/h	$7,659.63	72B급 FP8/4bit 운영 후보
g5.48xlarge	8x NVIDIA A10G	$16.288/h	$11,890.24	대형 VLM 자체 운영
p4d.24xlarge	8x NVIDIA A100	$21.958/h	$16,029.08	70B+ 대형 모델 안정 운영
p5.48xlarge	8x NVIDIA H100	$55.04/h	$40,179.20	최고성능, 비용 과다

AWS GPU 자체 배포 월 고정비(730h, USD)

g6.x	587.50
g5.x	734.38
g6e.x	1358.53
g5.12x	4140.56
g6e.12x	7659.63
g5.48x	11890.24
p4d	16029.08
p5	40179.20

5. 자체 배포 모델 후보

모델	유형	예상 GPU	월 비용	판단
Llama 3.2 11B Vision	VLM open-weight	g5.xlarge/g6.xlarge, 4bit	$587~734	자체 배포 실험 1순위
Pixtral 12B	VLM open-weight	g5.xlarge/g6.xlarge	$587~734	Llama 대안
Molmo 7B/8B	VLM open-weight	g6.xlarge급	$587+	저비용 기준선. 견적 JSON 품질 검증 필요
Qwen2.5-VL 32B	VLM open-weight	g6e.xlarge 또는 g5.12xlarge	$1,358~4,140	품질 실험용
Qwen2.5-VL 72B	VLM open-weight	g6e.12xlarge/p4d 이상	$7,659~16,029+	현재 프로젝트 운영용 비추천

자체 배포 손익분기점

자체 배포 기준	월 비용	GPT-5 mini 대비 손익분기 요청 수
g6.xlarge	$587.50	약 258,000건/월
g5.xlarge	$734.38	약 323,000건/월
g6e.xlarge	$1,358.53	약 597,000건/월
g5.12xlarge	$4,140.56	약 1,820,000건/월

현재 예상 트래픽이 월 수십만 건 미만이면 API가 비용상 유리하다. 자체 배포는 데이터 통제, 벤더 의존도 감소, 장기 대량 트래픽이 목적일 때 의미가 커진다.

6. 완성도/운영성 점수

모델	견적 품질	이미지 이해	JSON	지연	비용	운영	총점
GPT-5 mini	4.5	4.0	5.0	4.0	4.5	5.0	27.0
Gemini 2.5 Flash	4.0	4.3	4.0	4.7	4.5	4.5	26.0
Gemini 2.5 Flash-Lite	3.3	3.7	3.5	5.0	5.0	4.5	25.0

모델	견적 품질	이미지 이해	JSON	지연	비용	운영	총점
Claude Sonnet	4.8	4.0	4.3	3.8	2.5	4.5	23.9
Qwen2.5-VL 32B self-host	4.0	4.5	3.5	2.0	1.5	1.8	17.3
Llama 3.2 11B Vision self-host	3.2	3.5	3.0	2.8	2.0	2.5	17.0
Pixtral 12B self-host	3.2	3.5	3.0	2.8	2.0	2.5	17.0
Qwen2.5-VL 72B self-host	4.5	4.8	3.8	1.5	1.0	1.0	16.6

OpenCV 사진 전처리 파이프라인 종합 성능 평가

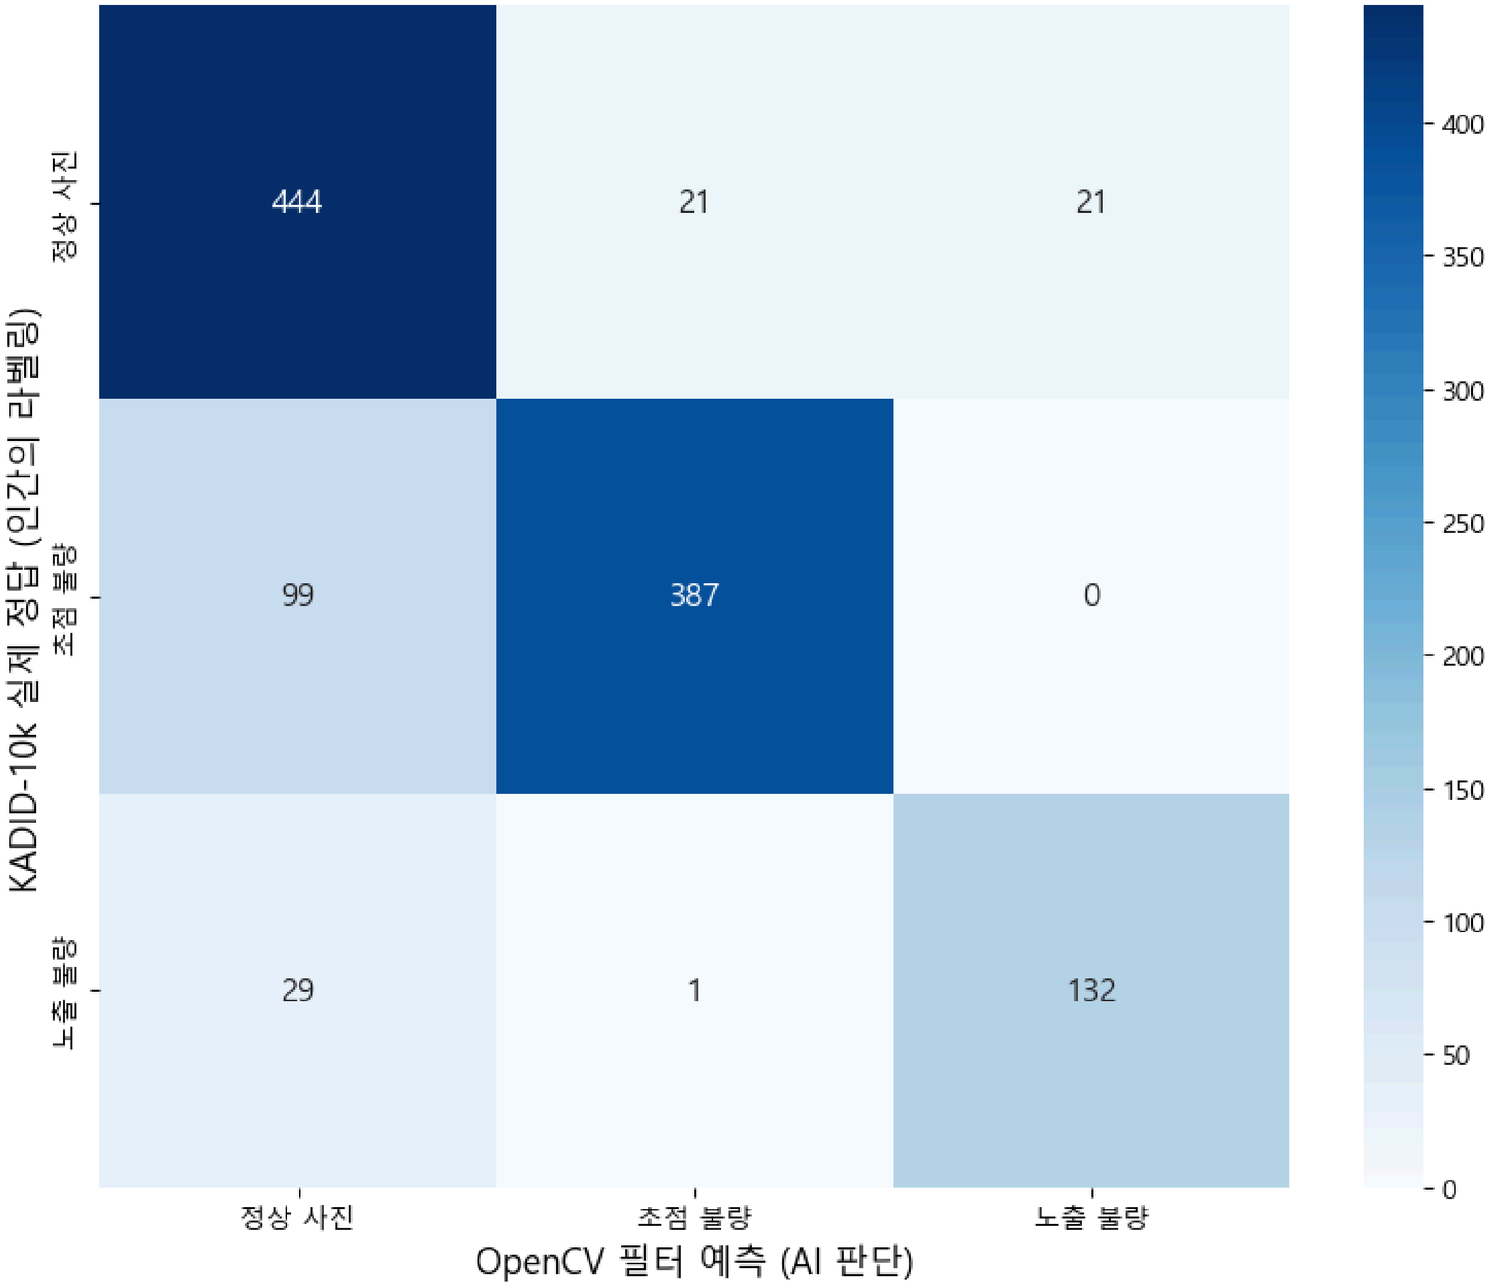

스페이스

허공답보_tuktak

요약 | 백로그 | 보드 | 코드 | 타임라인 | 문서 | 형식 | 개발 +

백로그 검색 | 필터

Sprint 2 (7월 2주차) 6 7월 – 13 7월 (7개의 업무 항목) 스프린트 완료

SCRUM-129	Front Project_Partner Page 개별 구현	FRONT PROJECT_PAR...	완료	7월 8일	
SCRUM-137	Front Project_Partner Page 통합	FRONT PROJECT_PAR...	완료	7월 7일	
SCRUM-138	AI Project 서비스 흐름 확장	AI PROJECT 서비스 흐...	완료	7월 8일	
SCRUM-139	AI 서비스 각 단계별 세부 test/설계	AI 서비스 각 단계별 세부 ...	해야 할 일	7월 10일	
SCRUM-140	AI Project 개발 환경 구축	AI PROJECT 개발 환경 ...	완료	7월 9일	
SCRUM-141	AI Project Service (api) 구현	AI PROJECT SERVICE...	완료	7월 13일	
SCRUM-142	산출물	산출물	완료	7월 13일	

+ 만들기

Sprint 3 (7월 3주차) 14 7월 – 20 7월 (6개의 업무 항목) 스프린트 완료

SCRUM-131	AI 서비스 각 단계별 세부 평가 설계	AI 서비스 각 단계별 세부 ...	완료	7월 14일	
SCRUM-132	AI 서비스 각 단계별 세부 평가 실시	AI 서비스 각 단계별 세부 ...	완료	7월 16일	
SCRUM-133	Frontend 통합 디자인 수정	FRONTEND 통합 디자인 ...	완료	7월 15일	
SCRUM-134	AI 서비스 구현	AI 서비스 구현	진행 중	7월 17일	
SCRUM-135	AI 서비스 서버 배포	AI 서비스 서버 배포	해야 할 일	7월 19일	
SCRUM-136	산출물	산출물	진행 중	7월 13일	

+ 만들기

Sprint 4 (7월 4주차) 20 7월 – 26 7월 (1개의 업무 항목) 스프린트 시작

Jira 업무 항목

SCRUM-91 / SCRUM-132

AI 서비스 각 단계별 세부 평가 실시

완료 | 완료 | 업무 유형 작업 개선

설명

원본 Monday 구분: 상위 Task
원본 담당자/참여자: 백승우, 전지원, 김지인
기간: 2026-07-14 ~ 2026-07-16
우선순위: High
스프린트: sprint 3 (7월 3주차)

첨부 파일 6

OpenCV_파라미... 보고서.pd
16 7월 2026, 06:09 오후

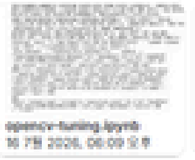
opencv-tuning.ipynb
16 7월 2026, 06:09 오후

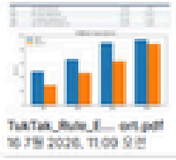
TukTak_Rule_E... ort.pdf
16 7월 2026, 11:09 오전

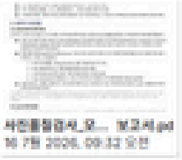
사인물점검지_모... 보고서.pd
16 7월 2026, 09:32 오전

하위 작업

100% 완료

업무		우선...	담당자	상태
SCRUM-210	텍스트(사용자 설명) 유효성 검사 rule-engine / 파라미터	M...	백	완료
SCRUM-211	이미지 임베딩 모델 / 유사도 검색 방식 / 파라미터	M...	전	완료
SCRUM-212	이미지 유효성 검사 모델 / 파라미터	M...	김	완료

연결된 업무 항목

연결된 업무 항목 추가

세부 사항

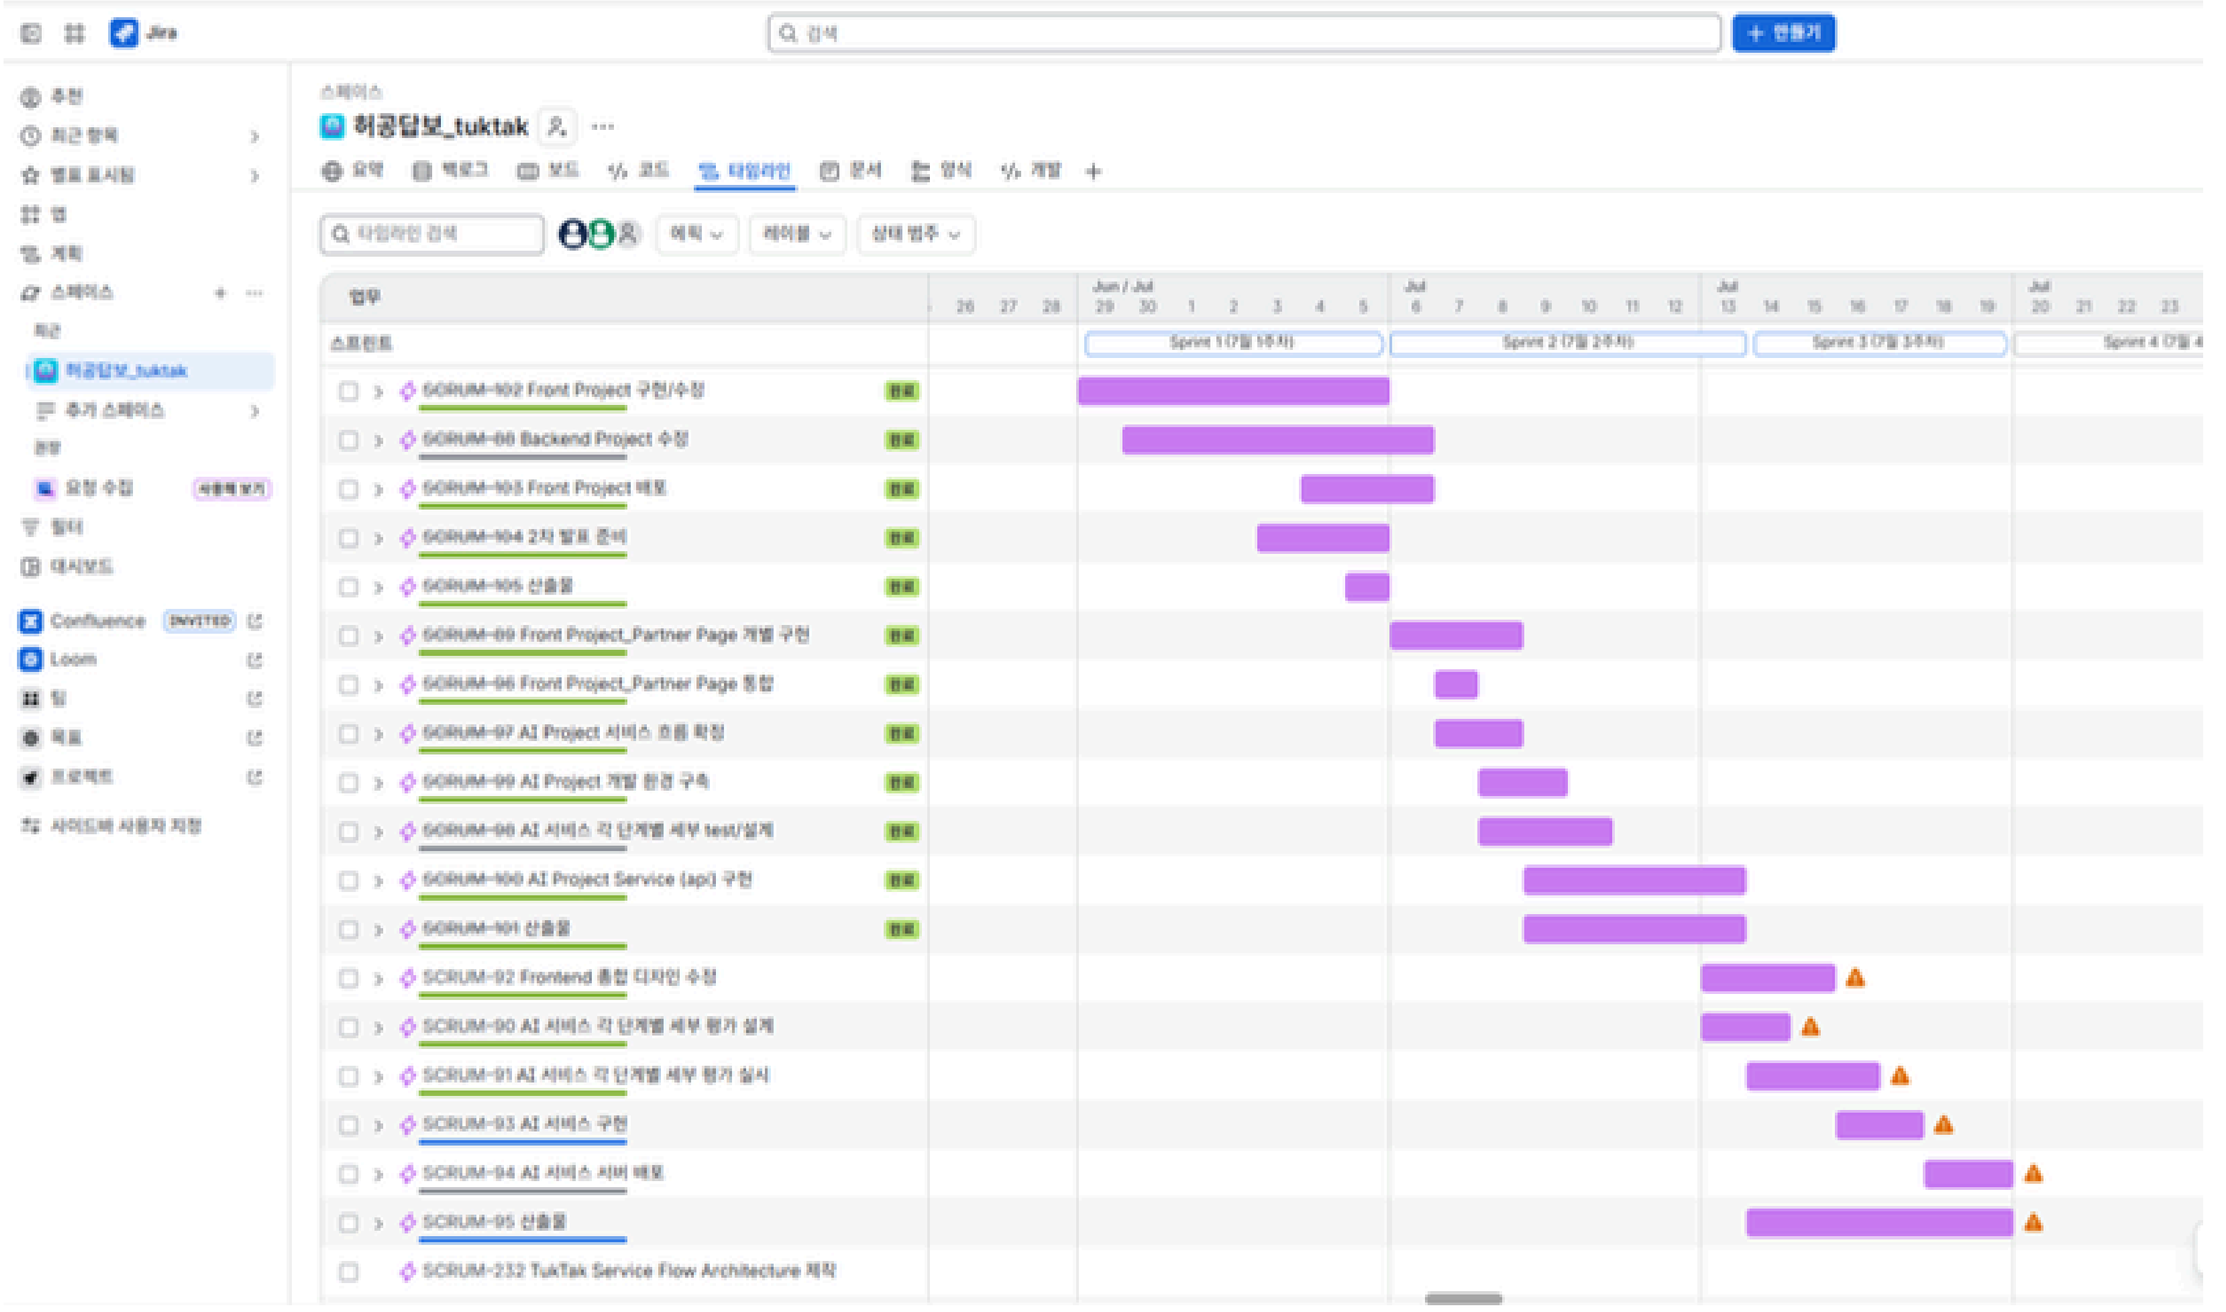
Jira
검색
만들기
추천
최근 항목
별표 표시됨
앱
계획
스페이스
최근
허공답보_tuktak
추가 스페이스
요청 수집
필터
대시보드
Confluence
Loom
팀
목표
프로젝트
사이드바 사용자 지정
스페이스
허공답보_tuktak
요약
백로그
보드
코드
타임라인
문서
양식
개발
타임라인 검색
에픽
레이블
상태 범주
업무
Jun / Jul
Jul
Sprint 1 (7일 1주차)
Sprint 2 (7일 2주차)
Sprint 3 (7일 3주차)
SCRUM-102 Front Project 구현/수정
SCRUM-66 Backend Project 수정
SCRUM-103 Front Project 배포
SCRUM-104 2차 발표 준비
SCRUM-105 산출물
SCRUM-69 Front Project_Partner Page 개별 구현
SCRUM-96 Front Project_Partner Page 통합
SCRUM-97 AI Project 서비스 흐름 확정
SCRUM-99 AI Project 개발 환경 구축
SCRUM-98 AI 서비스 각 단계별 세부 test/설계
SCRUM-100 AI Project Service (api) 구현
SCRUM-101 산출물
SCRUM-92 Frontend 통합 디자인 수정
SCRUM-90 AI 서비스 각 단계별 세부 평가 설계
SCRUM-91 AI 서비스 각 단계별 세부 평가 실시
SCRUM-93 AI 서비스 구현
SCRUM-94 AI 서비스 서버 배포
SCRUM-95 산출물
SCRUM-232 TukTak Service Flow Architecture 제작

Solution

TukTak만의 차별화 포인트

타사 서비스와의 기능 비교

비교 항목	TukTak	숨고	미소	오늘의집
사진 기반 AI 견적	O	X (이미지 데이터 미사용)	X (시간·평수 기준 정찰가 예약)	X (표준항목 견적계산기)
시공자 견적 무료 발송	O	X (건당 비용 발생)	X (크레딧 시스템)	X (월정액 구독료)
AI 리스크 리포트	O	X	X	X
역경매 방식 견적 비교	O (AI 기준서 기준 가격)	O (정찰 기준가 없는 경쟁)	O (견적 최대 4개 비교 가능)	X (상담사 1:1 매칭 방식)
고객·시공자 직접 실시간 채팅	O	O	O	X (상담사 매개 방식)

메인 테이블 ERD

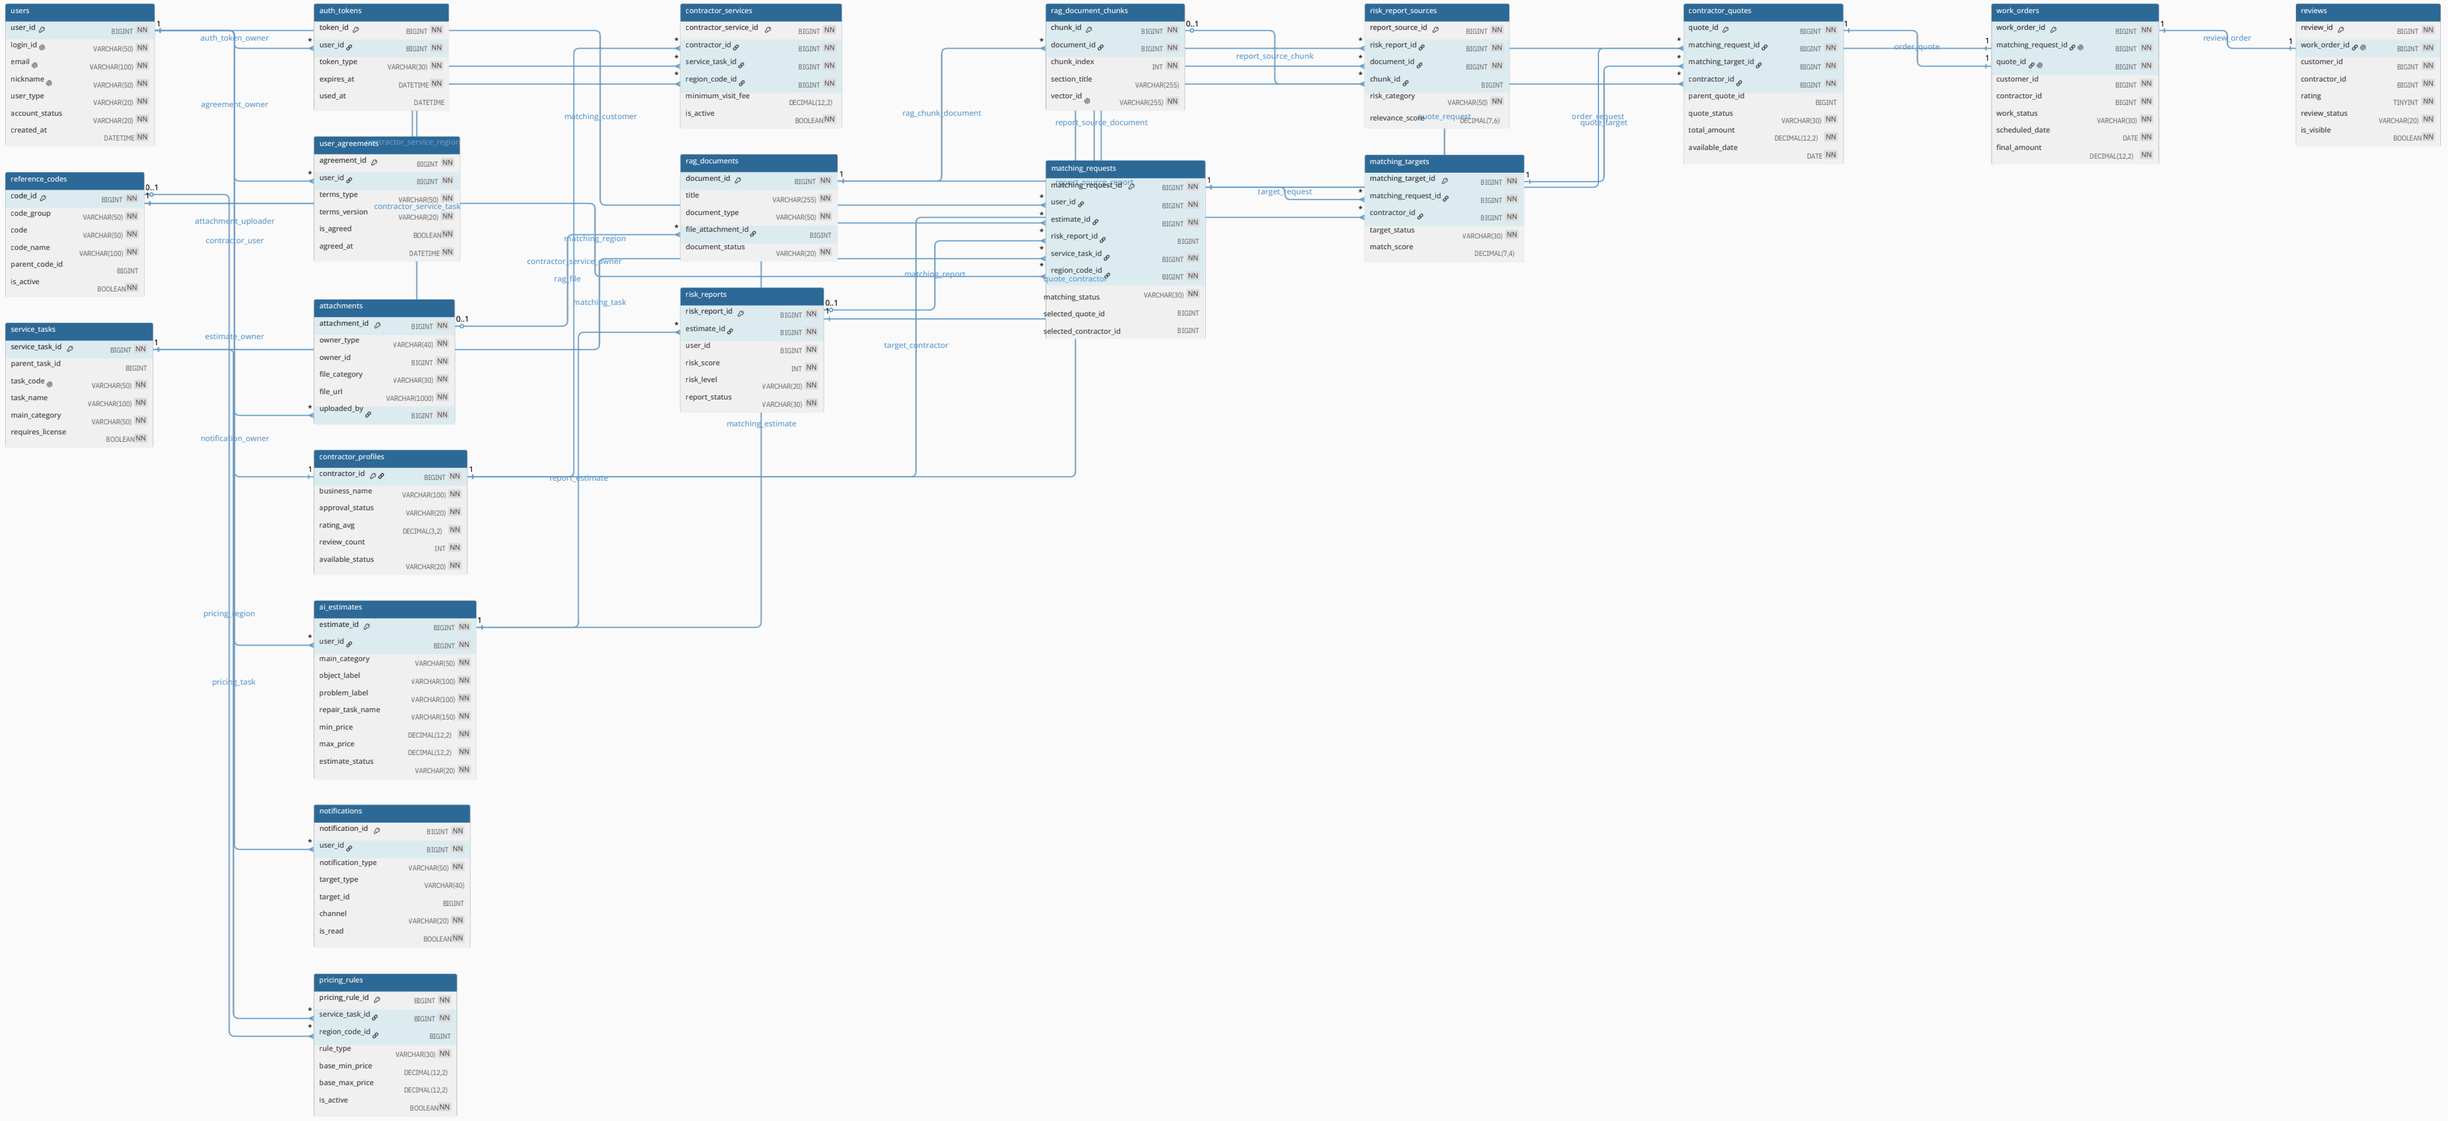

dbdiagram.io